Intensidad energética anual de edificios de Seattle: ¿cuánto se puede anticipar con información hasta dos años antes?

EYP3407 Tópicos Aplicados en Estadística · Proyecto aplicado, caso 04

Juan Pablo Cuevas · Cristóbal Honorato · Michelle Houngbo · Maximiliano León

10 de noviembre de 2026

1. Resumen ejecutivo

Problema. El programa de reporte energético de Seattle recibe cada año la intensidad energética (EUI, kBtu/pie²) de más de 3000 edificios no residenciales y multifamiliares, pero en enero del año a todavía no está completo el reporte de $a-1$. Evaluamos qué tan bien se anticipa la EUI anual de un edificio conocido con información hasta $a-2$, para fijar al inicio del año un valor esperado por edificio.

Resultado principal. El procedimiento elegido en desarrollo (2019–2021) fue un lasso sobre log(EUI). En la prueba 2023–2024 (7001 edificio–año de 3638 edificios) su MAE fue 9,86 kBtu/pie², 0,84 menos que repetir la EUI de $a-2$ (intervalo 95 % por remuestreo de edificios: [−1,40; −0,23]). La ventaja se concentra en 631 filas sin EUI en $a-2$, donde la referencia usa la mediana del tipo: ellas explican 0,69 de los 0,84. Frente a la última EUI disponible, la diferencia fue −0,15 [−0,63; 0,38]. En desarrollo ningún modelo superó a la referencia.

Recomendación. Anticipar la EUI con la historia del propio edificio: la última EUI reportada hasta $a-2$ rinde casi como el lasso, que aporta sobre todo cuando no hay historia. No usar el lasso en edificios con consumo previo extremo ($\geq$ 283 kBtu/pie²), donde subestima.

Limitación principal. Es una evaluación retrospectiva con dos años de prueba. Los choques comunes de un año, como la pandemia en 2020–2021, cambian el signo de las diferencias, y el intervalo no incorpora esa variación.

2. Problema y datos

2.1. Pregunta, usuario y decisión

La pregunta del caso es qué tan bien se anticipa la intensidad energética anual de edificios conocidos con sus atributos y su historial reportado. La dirigimos a quien administra el programa de reporte o planifica programas de eficiencia: al comenzar el año a necesita un valor esperado de EUI por edificio, por ejemplo para priorizar seguimiento o asistencia técnica, sin esperar el reporte de $a-1$, incompleto en enero (ficha del caso; EYP3407, 2026). Se trata de predecir un resultado futuro, no de describir reportes ya registrados; como no hay versiones históricas de la base, la evaluación es retrospectiva bajo un supuesto de información (sección 3.2) y no mide el rendimiento operativo real.

2.2. Población, unidad y respuesta

Una fila es un edificio–año objetivo, con clave `osebuildingid` y `datayear` (el código comprueba que no se repite). La respuesta es `siteeui_kbtu_sf`, la energía consumida en el sitio durante el año calendario dividida por la superficie bruta, en kBtu/pie². La predicción se emite al comenzar el año a y solo usa registros de años $\leq a-2$. La población son los edificios del programa con un reporte válido de EUI en el año objetivo (2017–2021 en desarrollo, 2023–2024 en prueba). Un edificio entra en cada año en que tiene respuesta, tenga o no historia, sin exigir que reporte en años futuros; las filas sin respuesta se excluyen y no se imputan. Las conclusiones valen para esta población, no para edificios fuera del programa ni para los años en que un edificio no reportó.

En desarrollo la EUI tiene mediana 37,2 kBtu/pie², percentil 99 de 283 y máximo 1538: es muy asimétrica. Su mínimo es 0,1, sin ceros ni negativos, de modo que el logaritmo está definido y reduce la asimetría (Anexo A.3).

2.3. Procedencia y fechas

Los datos provienen del programa *Seattle Building Energy Benchmarking*: la Office of Sustainability and Environment de Seattle los publica en el portal de datos abiertos de la ciudad como *Building Energy Benchmarking Data, 2015-Present* (conjunto `teqw-tu6e`; City of Seattle, 2026). Según los metadatos del conjunto, consultados el 9 de noviembre de 2026, son de dominio público, así que la copia puede publicarse en el repositorio citando a esa oficina. Usamos la copia del curso, `caso04_seattle_edificios.zip`, preparada el 12 de octubre de 2026: `datos.csv` con 34 699 registros edificio–año de 3823 edificios y 46 columnas, `diccionario.csv` con las descripciones de la fuente y `LEEME.txt`. Los originales no se editan: todo filtro y transformación está en el código. Distinguimos tres fechas: la del fenómeno (el año calendario del consumo, `datayear`), la del registro (el reporte se entrega después de terminado el año y puede corregirse más tarde) y la de descarga (octubre de 2026). Como solo tenemos la versión descargada, un valor de 2019 puede incluir correcciones posteriores, y los atributos físicos repiten en todos los años el valor actual (sección 2.5).

2.4. Construcción de la muestra

Tabla 1: Construcción de la muestra. Desarrollo: objetivos 2017–2021, de los que se evalúan 2019–2021 (2017 y 2018 solo entrenan). Prueba: objetivos 2023–2024.

Paso	Desarrollo: filas	Desarrollo: edificios	Prueba: filas	Prueba: edificios
Filas objetivo del período	17 255	3632	7399	3749
Con respuesta (EUI del año)	16 657	3607	7006	3640
Sin errores de registro	16 650	3607	7001	3638
Filas evaluadas	10 035	3575	7001	3638

La Tabla 1 y la Figura 1 muestran la construcción. Los registros de 2017–2021 son objetivos de desarrollo y los de 2023–2024, objetivos de prueba; 2015, 2016 y 2022 solo aportan historia. Salen las filas sin EUI del año (598 en desarrollo y 393 en prueba) y las marcadas como error de registro (7 y 5; sección 2.5). Cada año entran y salen edificios: entre 2016 y 2022 hubo entre 50 y 93 altas y entre 4 y 19 bajas por año (Anexo A.3). Por eso no todas las filas tienen EUI en $a-2$. En prueba, 631 filas (9,0 %) solo tienen historia más antigua, frente a 75 (0,7 %) en desarrollo, porque en 2021 y 2022 faltan 419 y 345 respuestas, contra 33 a 57 por año en 2015–2020. Este cambio es clave para leer los resultados de prueba.

La base es una sola tabla, con varias filas por edificio. A las 24 654 filas objetivo de 2017–2021 y 2023–2024 (3813 edificios) se unen la EUI de $a-2$ y la de $a-3$ por la clave edificio–año, de uno a uno, y la última EUI válida y el uso por el registro más reciente $\leq a-2$ del mismo edificio, de muchos a uno: si el edificio no volvió a reportar una EUI válida, su último registro sirve a varios años objetivo (858 filas comparten así su última EUI). Cada unión conserva filas y edificios (`resultados/uniones.csv`). Los 3692 edificios de 2015–2022 están en Seattle, en 13 barrios (de 83 a 617 edificios cada uno) y 29 códigos postales.

2.5. Calidad de los datos

Atributos copiados e identificadores. De las 44 columnas que no son clave, 21 no cambian dentro de ningún edificio en 2015–2022, entre ellas nombre, dirección, parcela, tipo, año de construcción, pisos, número de edificios, las seis superficies del edificio (confirmadas y autodeclaradas), barrio, distrito, coordenadas y la marca de demolición: la base repite el valor actual en todos los años, de modo que

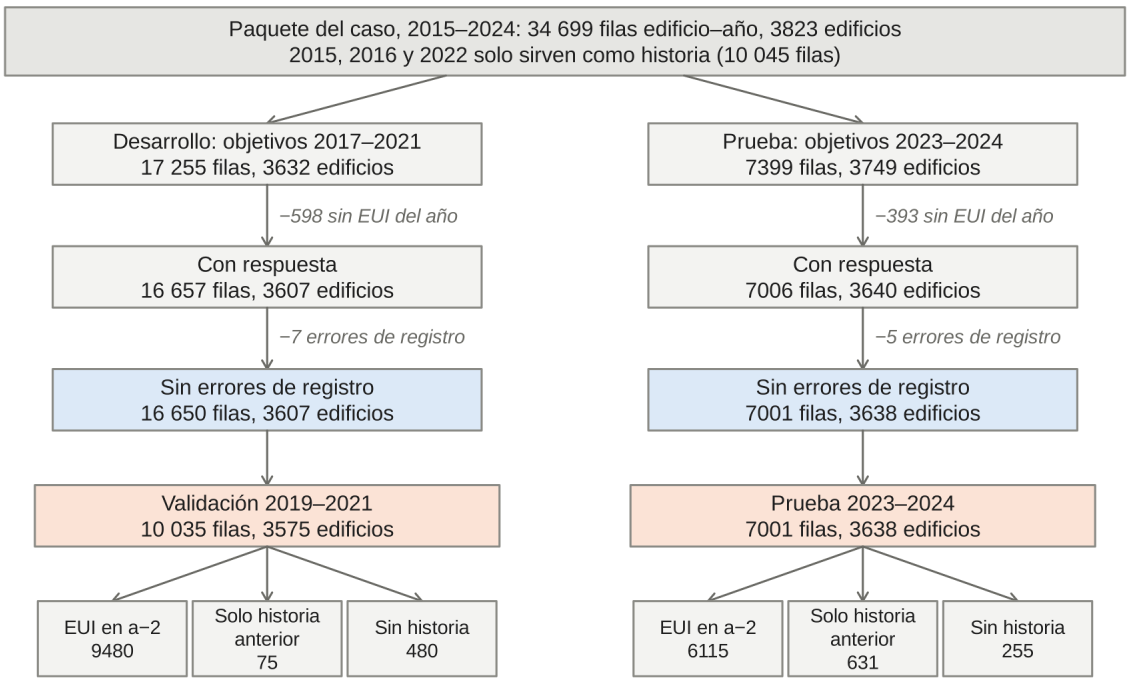


Figura 1: Construcción de la muestra. Filas edificio–año y edificios en cada paso, para desarrollo (izquierda) y prueba (derecha). Las filas sin EUI del año salen sin imputar, y las marcadas por la regla de errores de registro no se usan como objetivo ni como historia. En azul, los objetivos válidos; en naranja, las filas evaluadas, que las cajas inferiores separan según la historia disponible al predecir. Las filas que solo tienen historia anterior a $a-2$ pasan de 75 en desarrollo a 631 en prueba, un cambio que explica buena parte de los resultados de la sección 5.2.

los cambios de nombre no se pueden auditar. Los usamos bajo el supuesto declarado de características estables: si un edificio se amplió, su superficie actual se aplica también a años anteriores. Hay 39 direcciones y 22 nombres repetidos entre edificios distintos, pero ningún par de dirección y nombre, así que no encontramos un edificio con dos identificadores. Las columnas de uso sí cambian (el uso principal, en 331 edificios), por lo que se toman del último registro $\leq a-2$ (Anexo A.4).

Códigos especiales, faltantes y categorías. Hay 66 filas con 0 pisos y 284 con 0 edificios; los tratamos como dato ausente. En 1398 filas hay un segundo uso sin su superficie. En el entrenamiento final, 33 de las 61 categorías del uso principal tienen menos de 30 filas y pasan a «Otro» (343 filas, 2,1 %), y 730 filas sin registro previo de uso van a «Sin dato» (sección 4.1); el tipo y el barrio no tienen categorías raras. Hay 83 parcelas con más de un edificio, pero no se une información por parcela: la unidad es el edificio del programa.

Superficies. La superficie confirmada por la ciudad, que usamos como predictor, es positiva (mínimo 16 092 pie^2) y siempre igual a la de los edificios más el estacionamiento. La autodeclarada en Portfolio Manager difiere en más de 10 % de la confirmada en 1034 de los 3692 edificios (97 la declaran 0), y en 2466 filas la superficie del uso principal supera en más de 10 % la de los edificios. Usamos la confirmada y no las autodeclaradas, y la fracción del uso principal se calcula sobre la suma de las superficies de uso, de modo que queda entre 0 y 1. Un edificio tiene un estacionamiento confirmado negativo (-3 pie^2 en 8 filas), un valor imposible, pero despreciable frente a su superficie.

Errores de registro frente a extremos válidos. Antes de ajustar modelos fijamos una regla que solo mira años anteriores: un registro es error si su EUI supera 10 veces la mediana de las EUI previas

del mismo edificio y además supera 1000 kBtu/pie², valores incompatibles con la historia del edificio, como los de un error de unidades. Marca 9 registros en 2015–2022 (Anexo A.5; por ejemplo, 42 480 con una mediana previa de 23,5) y 5 en 2023–2024; no se usan como objetivo ni como historia. No se marcan los saltos a niveles posibles (de 0,4 a 42,1 puede ser una recuperación) ni las caídas, porque un edificio puede vaciarse. Los consumos altos con historia coherente se conservan: el mayor valor de desarrollo, 1538 kBtu/pie², es de un centro de datos que reportaba 1167 dos años antes.

2.6. Variables admisibles y excluidas

La Tabla 2 resume la auditoría de las columnas. Las medidas de consumo, emisiones y ENERGY STAR del año objetivo contienen o reflejan la respuesta y se excluyen; no reconstruimos la EUI con sus componentes. El cumplimiento y la marca de demolición se determinan después del año objetivo, y el distrito usa límites de 2023.

3. Diseño de evaluación

3.1. Particiones temporales

Usamos ventanas temporales que crecen (Figura 2; Hyndman y Athanasopoulos, 2021), porque el uso es predecir años futuros de edificios conocidos. Para validar el año a se entrena solo con objetivos hasta $a-2$, de modo que las etiquetas también respetan el retraso del reporte: la ventana 1 entrena con 2017 y valida 2019; la 2, con 2017–2018 y valida 2020; la 3, con 2017–2019 y valida 2021. Un edificio aparece en entrenamiento y en validación, como ocurrirá al usar el modelo; los edificios nuevos se estudian en la sensibilidad S2. Tras elegir, el procedimiento se reajusta con los objetivos 2017–2021 y se evalúa una sola vez en 2023 (historia hasta 2021) y en 2024 (historia hasta 2022).

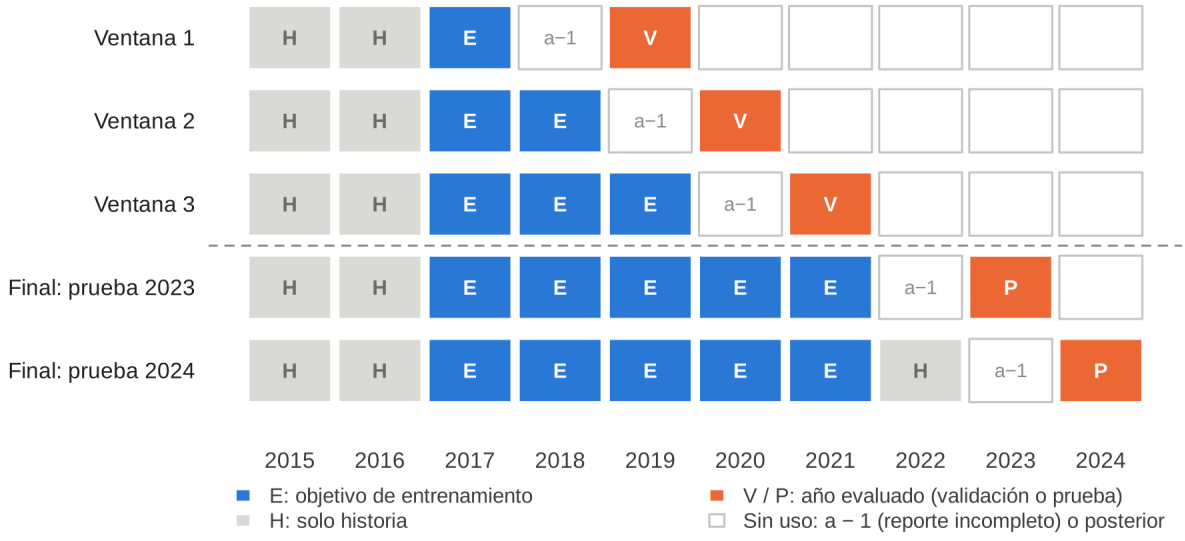


Figura 2: Diseño temporal. Cada fila es un ajuste. Los objetivos de entrenamiento (E) y el año evaluado (V en validación, P en prueba) usan predictores de años $\leq a-2$; el año $a-1$ nunca se usa. Los años H solo aportan historia. Las ventanas de desarrollo crecen y el ajuste final, con objetivos 2017–2021, se evalúa una sola vez en 2023 y 2024; 2022 solo sirve como historia para 2024.

Tabla 2: Variables admisibles y excluidas. Tipo: cat., categórica; num., numérica. Clase: identificador, dato de entrada, atributo o resultado posterior al año objetivo, respuesta o variable derivada de ella. «Valor actual»: la base repite en todos los años el valor vigente del edificio (columnas sin cambios, Anexo A.4).

Columnas: interpretación (tipo)	Clase	Disponible al predecir a	Decisión
`osebuildingid`, `datayear`: edificio (texto) y año del reporte (num.)	Identificador	—	Clave edificio–año; no son predictores.
`buildingname`, `address`, `taxparcel...`, `city`, `state`, `zipcode`, `latitude`, `longitude`: nombre, ubicación exacta y parcela (texto y num.)	Identificador	Valor actual en todos los años	Excluidas: identifican al edificio; la ubicación entra como barrio.
`neighborhood`: barrio (cat., 13 niveles)	Entrada	Valor actual	Incluida.
`councildistrictcode`: distrito del concejo municipal (cat.)	Posterior	Límites de noviembre de 2023	Excluida: límites posteriores a casi todos los años objetivo.
`buildingtype`, `yearbuilt`, `numberoffloors`, `numberofbuildings`: tipo de edificio (cat.); año de construcción, pisos y edificios de la propiedad (num.)	Entrada	Valor actual	Incluidas: tipo, antigüedad (a menos el año de construcción), log de pisos y log de edificios.
`propertygfatotal`, `propertygfaparking`: superficie bruta total y de estacionamiento, confirmadas por la ciudad (num., pie²)	Entrada	Valor actual	Incluidas: log de la superficie y fracción de estacionamiento.
`propertygfabuildings` y tres autodeclaradas (`selfreport...`): superficie sin estacionamiento y superficies autodeclaradas (num., pie²)	Entrada	Valor actual	Excluidas: total menos estacionamiento, y autodeclaradas menos coherentes (sección 2.5).
Usos 1.º a 3.º y sus superficies (`largestpropertyusetype`, ...): tres usos de mayor superficie (cat.) y la superficie de cada uno (num., pie²)	Entrada	Último registro $\leq a-2$	Incluidas: uso principal, fracción de superficie del uso principal y número de usos.
`epapropertytype`: tipo de propiedad de la EPA (cat.)	Entrada	Último registro $\leq a-2$	No usada: otra clasificación del mismo uso principal.
`siteeui_kbtu_sf`: energía del sitio por pie² de superficie bruta (num., kBtu/pie²)	Respuesta	Año a: se predice; $\leq a-2$: historia	Se predice; su historia entra como log de la última EUI válida y de la EUI de $a-3$, con indicadoras.
13 medidas del año (`siteenergyuse_kbtu`, `electricity_kwh`, ...): consumo, emisiones y ENERGY STAR del mismo año (num.)	Derivada de la respuesta	Año a: no disponibles	Excluidas por fuga; sus valores $\leq a-2$ repetirían la historia de la EUI.
`compliancestatus`, `complianceissue`, `demolished`: cumplimiento del reporte (texto) y demolición (lógica)	Posterior	Al cierre del reporte; demolición, ciclo 2023	Excluidas.

3.2. Información disponible

Cada predictor se construye con registros de años $\leq a-2$, en las filas evaluadas y en las de entrenamiento, y el código se detiene si alguna variable de historia viene de $a-1$ o de un año posterior. En una corrida aparte (`verificacion/fuga.R`) alteramos al azar la EUI y los usos de los años posteriores a cada corte: las predicciones de las 35 configuraciones, de la referencia y de la prueba quedaron idénticas, y las que sí usaban años alterados cambiaron. Suponemos que en enero del año a están disponibles los reportes hasta $a-2$ tal como aparecen en la copia descargada, y que los atributos copiados describen al edificio en ese momento; si los reportes se corrigieron después, la evaluación es optimista.

3.3. Métricas, referencia y regla de selección

La métrica principal es el MAE en kBtu/pie², sobre las filas reunidas de las tres ventanas, de modo que cada edificio–año pesa lo mismo; el RMSE, complementario, es sensible a pocos errores grandes. Como el panel repite edificios, en prueba informamos también el MAE por edificio y el error absoluto dividido por la mediana de su tipo en el entrenamiento. Todos los procedimientos se comparan en las mismas filas, con exclusiones comunes. La referencia de la ficha predice la EUI de $a-2$ y, si no existe, la mediana de la EUI del tipo en el entrenamiento. Como la ficha no dice qué hacer cuando falta $a-2$ pero hay años anteriores, antes de abrir la prueba fijamos además una referencia alternativa con la última EUI válida hasta $a-2$, que solo se informa. La regla elige, dentro de cada familia y entre familias, el menor MAE reunido; un empate exacto iría a lo más simple.

3.4. Congelamiento e incertidumbre

Antes de evaluar la prueba registramos en `CONGELADO.md`, con fecha y huella md5 del código, la población, la regla de calidad, las variables, los modelos, la búsqueda, la métrica, la regla de selección y el procedimiento elegido. Para la incertidumbre remuestreamos edificios con reposición (Davison y Hinkley, 1997), con 2000 réplicas y semilla 3407: cada edificio aporta todas sus filas a la vez, lo que respeta la dependencia entre sus años. Con predicciones fijas, el intervalo de percentiles 95 % de la diferencia de MAE es condicional a los ajustes: no incluye la incertidumbre de selección y entrenamiento ni la de choques comunes a un año, que examinamos comparando años (sección 5.3). La dispersión entre ventanas, que comparten datos, no se interpreta como un intervalo de confianza.

4. Métodos

4.1. Preprocesamiento común

Todo lo que se aprende se calcula con el entrenamiento de cada ventana y se aplica sin recalcular a la validación o a la prueba:

- **Respuesta:** log(EUI).
- **Historia:** log de la última EUI válida hasta $a-2$ (sin historia, la mediana de log(EUI) del entrenamiento, con indicadora); indicadora de historia antigua (última EUI anterior a $a-2$) y log de la EUI de $a-3$ (si falta, se repite la última, con indicadora).
- **Uso** (último registro $\leq a-2$): uso principal, fracción de superficie del uso principal y número de usos; un faltante toma la mediana del entrenamiento, con indicadora.
- **Edificio:** log de la superficie, fracción de estacionamiento, antigüedad, log de pisos y log de número de edificios (un 0 toma la mediana del entrenamiento), tipo y barrio.
- **Categorías:** con menos de 30 filas de entrenamiento pasan a «Otro»; un valor ausente, a «Sin dato»; una categoría no vista, a la más frecuente.

Son 16 predictores; con las indicadoras de categorías, el lasso usa en promedio 49 columnas, que glmnet estandariza internamente. Los modelos se ajustan sobre log(EUI) y predicen con exp(). Si el residuo en log tiene mediana 0, exp() de la predicción es la mediana condicional de la EUI, que es la predicción que minimiza el error absoluto esperado y, por tanto, la coherente con el MAE. No buscamos la media condicional, que exigiría un factor de corrección. El supuesto se comprueba en la sección 5.1.

4.2. Procedimientos y expectativas

Los tres métodos se describen en James et al. (2021, caps. 6 a 8). Las expectativas se escribieron antes de ajustar:

- **M1, lasso** (Tibshirani, 1996; glmnet, Friedman et al., 2010): persistencia en escala log, porque la historia entra en forma lineal, más ajustes aditivos por tipo, uso, tamaño y barrio, con selección de variables por la penalización. Puede fallar si los efectos no son lineales en log o cambian según el tipo.
- **M2, GAM** (Wood, 2017; mgcv): además, curvas suaves para historia, tamaño y antigüedad, con splines de regresión cuya suavidad se elige por REML (Wood, 2011). No captura interacciones, y con la historia de $a-2$ y la de $a-3$ juntas puede haber concurvidad.
- **M3, bosque aleatorio** (Breiman, 2001; ranger, Wright y Ziegler, 2017): capta interacciones como tipo × historia sin especificarlas. No extrapola fuera del rango visto y puede apoyarse en reconocer edificios ya vistos.

4.3. Búsqueda de hiperparámetros y costo

Lasso: 20 valores de λ en escala logarítmica, desde el que anula todos los coeficientes en la primera ventana (0,6019) hasta su milésima parte; una sola corrida por ventana entrega toda la grilla. GAM: tres fórmulas de complejidad creciente. G1 tiene una curva para la historia, las indicadoras de historia y el tipo; G2 agrega curvas para superficie y antigüedad, uso, barrio, estacionamiento y pisos; G3 agrega una curva para $a-3$ y las demás variables. Bosque: 300 árboles, `mtry` en {3, 5, 8, 12} y tamaño mínimo de nodo en {5, 20, 50}, 12 configuraciones; el error fuera de bolsa no se usa para elegir. Son 35 configuraciones, dentro del máximo de 20 por familia, evaluadas en las tres ventanas (Anexo A.1). La búsqueda completa tomó 76 s para el bosque, 24 s para el GAM y menos de 1 s para el lasso, con un núcleo.

5. Resultados

5.1. Desarrollo: validación en 2019–2021

Tabla 3: Comparación en desarrollo: 10 035 filas de validación (2019–2021), las mismas para todos. MAE y RMSE en kBtu/pie². La referencia predice la EUI de $a-2$ (si falta, la mediana del tipo). «Dif.» es el MAE del procedimiento menos el de la referencia en las mismas filas, reunido y por ventana; el intervalo remuestrea edificios con predicciones fijas.

Procedimiento	Configuración	MAE	RMSE	Dif.	IC 95 %	Dif. 2019	Dif. 2020	Dif. 2021
Referencia	—	10,44	24,0	—	—	—	—	—
Lasso (elegido)	$\lambda = 0{,}005332$	10,50	24,7	+0,06	[−0,19; 0,35]	+0,95	−0,61	−0,16
GAM	G1	10,52	24,5	+0,08	[−0,10; 0,28]	+0,88	−0,23	−0,44
Bosque	mtry 5, nodo 5	10,52	24,6	+0,08	[−0,14; 0,32]	+0,50	−0,18	−0,07

Ningún procedimiento superó a la referencia en el MAE reunido de desarrollo (Tabla 3). El lasso, elegido por tener el menor MAE de los tres, quedó 0,06 kBtu/pie² sobre la referencia, con intervalo [−0,19; 0,35]. Las diferencias por ventana cambian de signo: los tres modelos pierden en 2019 y el lasso gana en 2020 y 2021. Las diferencias entre los tres modelos (MAE entre 10,50 y 10,52) son mucho menores que

la variación entre ventanas, así que el orden entre familias es frágil. El lasso es además el más simple de interpretar y el más barato: conserva en promedio 23 de 49 coeficientes, frente a 16,6 grados de libertad efectivos del GAM y 300 árboles del bosque.

Supuestos. Dentro del entrenamiento, la mediana del residuo en log está entre 0,003 y 0,012 para los tres modelos, así que exp() entrega la mediana condicional en los años de ajuste. Fuera de muestra es negativa (lasso: −0,099, −0,044 y −0,009 en 2019, 2020 y 2021): los modelos sobrestiman por un choque común por año. La mediana del cambio de log(EUI) respecto de $a-2$ fue +0,060 en 2017, el único año de entrenamiento de la ventana 1, y −0,047 en 2019 (Figura 3B): un modelo entrenado con años de alza no anticipa uno de baja, mientras que la persistencia no aprende tendencias. El residuo en log tiene asimetría negativa (−1,6 en el lasso) por caídas grandes de consumo; la pendiente de calibración es 0,95, y la mediana del error absoluto en log se mantiene entre 0,09 y 0,14 en los quintiles del nivel predicho, aunque la predicción mediana va de 24 a 88 kBtu/pie²: el error relativo es casi estable y el absoluto crece con el nivel, lo que respalda la escala log. En el GAM, la prueba de dimensión de base de mgcv no indica falta de flexibilidad (índice 1,01, valor p 0,85) y la concurvidad de la curva de historia es baja (0,30 en el peor caso); el valor cercano a 1 de la parte paramétrica refleja que las indicadoras de tipo casi suman la constante. El lasso conserva entre 21 y 25 coeficientes según la ventana, y el de la historia es siempre el mayor (Anexo A.6).

5.2. Prueba: evaluación única en 2023–2024

Tabla 4: Comparación en prueba: 7001 filas de 3638 edificios (3496 en 2023 y 3505 en 2024), las mismas para todos. MAE y RMSE en kBtu/pie². «Dif.» es la diferencia de MAE con la referencia de la ficha; el intervalo remuestrea edificios con predicciones fijas. GAM y bosque se informan, pero no se usaron para elegir.

Procedimiento	MAE	RMSE	Dif. MAE	IC 95 %	MAE 2023	MAE 2024
Referencia: EUI de $a-2$	10,69	28,2	—	—	10,44	10,95
Ref. alternativa: última EUI	10,01	24,3	−0,69	—	9,73	10,28
Lasso (elegido)	9,86	26,3	−0,84	[−1,40; −0,23]	9,87	9,84
GAM G1	9,84	23,9	−0,85	[−1,25; −0,48]	9,97	9,71
Bosque	9,50	22,7	−1,19	[−1,73; −0,67]	9,49	9,51

En la prueba el lasso tuvo un MAE de 9,86 kBtu/pie², 0,84 menos que la referencia de la ficha (10,69), con intervalo [−1,40; −0,23] (Tabla 4). La ventaja fue mayor en 2024 (−1,11; [−1,74; −0,40]) que en 2023 (−0,57; [−1,21; 0,10], que incluye el 0). El GAM y el bosque, informados sin intervenir en la elección, también superaron a la referencia; el bosque tuvo el menor MAE (9,50), pero cambiar de procedimiento después de ver la prueba invalidaría la evaluación. El RMSE del lasso (26,3) es menor que el de la referencia, pero mayor que el de la referencia alternativa (24,3), porque comete algunos errores muy grandes (sección 5.3).

Tabla 5: MAE en prueba (kBtu/pie²) según la historia disponible. El aporte es la diferencia de MAE del lasso con la referencia en el grupo, ponderada por su fracción de filas; los tres aportes suman −0,839.

Historia disponible	n	Ref.	Ref. alt.	Lasso	GAM	Bosque	Aporte a la dif. del lasso
EUI en $a-2$	6115	9,20	9,20	9,08	9,05	8,64	−0,106
Solo historia anterior a $a-2$	631	22,77	15,13	15,16	15,30	15,46	−0,686
Sin historia	255	16,62	16,62	15,32	15,34	15,46	−0,047

¿Por qué el lasso gana en prueba y no en desarrollo? La Tabla 5 separa las filas según la historia disponible. En las 6115 filas con EUI en $a-2$, la ventaja del lasso es pequeña (9,08 frente a 9,20).

En las 631 filas que solo tienen historia más antigua, la referencia de la ficha usa la mediana del tipo y su MAE es 22,77; el lasso, que usa la última EUI, baja a 15,16. Esas filas aportan 0,69 de los 0,84 de ventaja, y en desarrollo eran apenas 75. La referencia alternativa, que también usa la última EUI, obtiene 15,13 en ese grupo. Frente a ella, el lasso gana 0,15 en total, con intervalo [−0,63; 0,38], y el signo cambia entre años (2023: +0,14; 2024: −0,44). Sin historia, el lasso mejora a la mediana del tipo en 1,3 kBtu/pie².

5.3. Análisis de errores

Choques por año y pandemia. La Figura 3A muestra que el error de todos los procedimientos cambia más entre años que entre procedimientos, y que el signo de la ventaja del lasso cambia de un año a otro. En 2021 todos tienen su mayor MAE (entre 11,35 y 11,80). La Figura 3B muestra el cambio de cada edificio respecto de $a - 2$: en 2020 y 2021 el rango intercuartil fue el mayor del período (0,227 y 0,215, frente a 0,14–0,16 en los demás años). En los edificios no residenciales la mediana del cambio fue −0,138 en log en 2020 (−13 %) y −0,096 en 2021, mientras en los multifamiliares de 5 a 9 pisos fue 0 en ambos años. Ese choque común de la pandemia hace que el desempeño en un año no garantice el del siguiente (pandemia por tipo en el Anexo A.7).

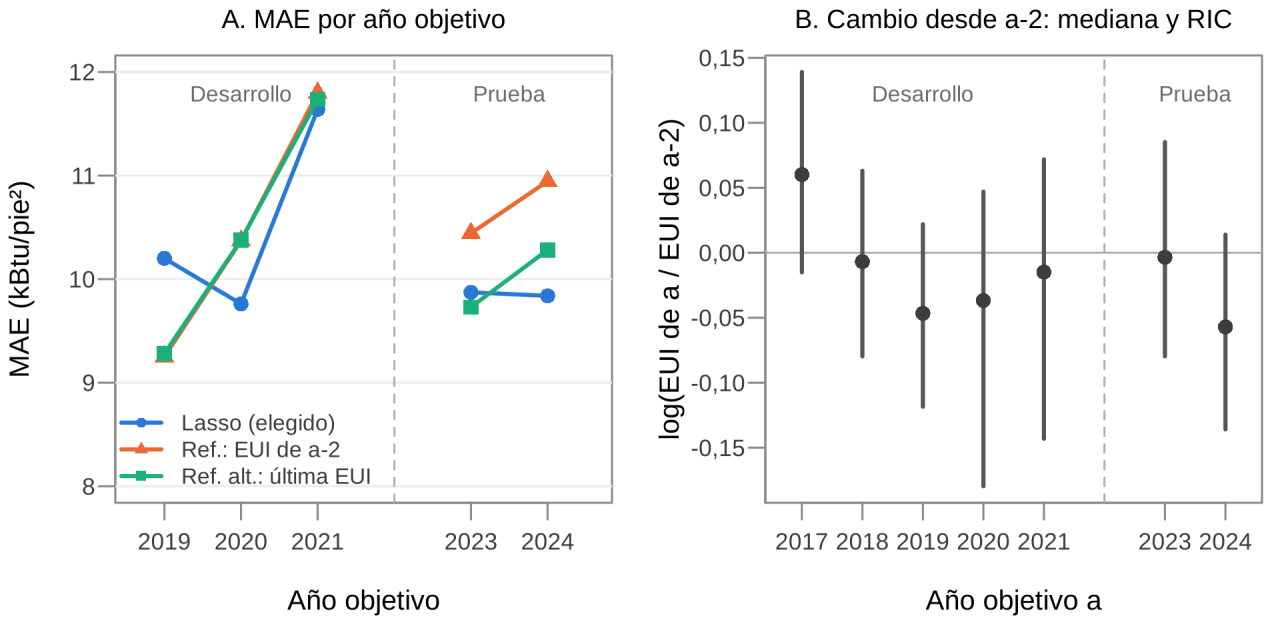


Figura 3: Error por año y choques comunes. A: MAE (kBtu/pie²) del lasso y de las dos referencias en cada año evaluado; en desarrollo, cada año usa su propia ventana y en prueba el ajuste final. B: mediana (punto) y rango intercuartil (RIC, barra) del cambio log(EUI de a / EUI de $a - 2$) en los edificios con ambos valores. La figura muestra que el error cambia más entre años que entre procedimientos y que en 2020–2021 los cambios fueron más dispersos, lo que limita trasladar el resultado de un año a otro.

Subgrupos. Por tipo de edificio, el lasso mejora a la referencia alternativa en multifamiliares y escuelas, y es peor en hospitales (+2,1), edificios no residenciales (+1,1) y universidades (+6,9, solo 69 filas). Por tamaño, es mejor en los tres quintiles menores de superficie y peor en los dos mayores (Tabla 6). Por uso principal (Anexo A.8), mejora a la referencia alternativa en vivienda multifamiliar (−1,0), bodegas, escuelas (−3,3) y lugares de culto, casi la iguala en oficinas (+0,1) y es peor en hoteles (+3,5), comercio minorista y el grupo de usos poco frecuentes (+3,3).

Consumo extremo. En las 62 filas cuya última EUI supera el percentil 99 del entrenamiento (283

Tabla 6: MAE en prueba (kBtu/pie²) por tipo de edificio y por quintil de superficie (pie², cortes del entrenamiento final). Mismas filas para todos los procedimientos en cada grupo.

Grupo	n	Ref.	Ref. alt.	Lasso	GAM	Bosque	Lasso − ref. alt.
Hospital	94	22,74	16,47	18,61	14,95	15,72	+2,15
Multifamiliar, 10 o más pisos	284	8,92	8,09	7,64	7,27	7,92	−0,45
Multifamiliar, 1 a 4 pisos	2054	7,69	7,43	6,03	6,79	5,74	−1,40
Multifamiliar, 5 a 9 pisos	1572	5,98	5,89	5,38	5,49	5,28	−0,51
No residencial	2644	15,53	14,27	15,37	14,85	14,94	+1,10
Escuela	284	9,20	9,23	6,31	7,75	6,63	−2,92
Universidad	69	19,32	19,30	26,20	20,28	19,17	+6,90
Superficie Q1 (< 26 964)	1293	11,07	10,31	10,08	10,18	9,93	−0,22
Superficie Q2 (26 964–38 630)	1384	11,18	10,84	9,81	9,95	9,35	−1,03
Superficie Q3 (38 630–60 375)	1377	10,40	9,77	9,16	9,35	8,75	−0,61
Superficie Q4 (60 375–125 607)	1432	10,27	9,49	10,00	9,82	9,52	+0,51
Superficie Q5 (≥ 125 607)	1515	10,60	9,69	10,19	9,93	9,93	+0,50

kBtu/pie²), el MAE del lasso es 113,2, frente a 89,8 de la referencia alternativa, y su predicción queda en mediana 27,4 kBtu/pie² bajo lo observado (Figura 4). La razón es estructural: en el lasso final la suma de los coeficientes de la historia (0,67 + 0,19 = 0,86) es menor que 1, así que en escala log la predicción se acerca al centro de la distribución y los valores muy altos se subestiman. En el resto de las filas el lasso es mejor que la referencia alternativa (8,93 frente a 9,29). El 1 % de las filas con mayor error concentra el 18,4 % del error absoluto y el 70,1 % del error cuadrático del lasso: el RMSE depende de pocos edificios (Anexo A.9).

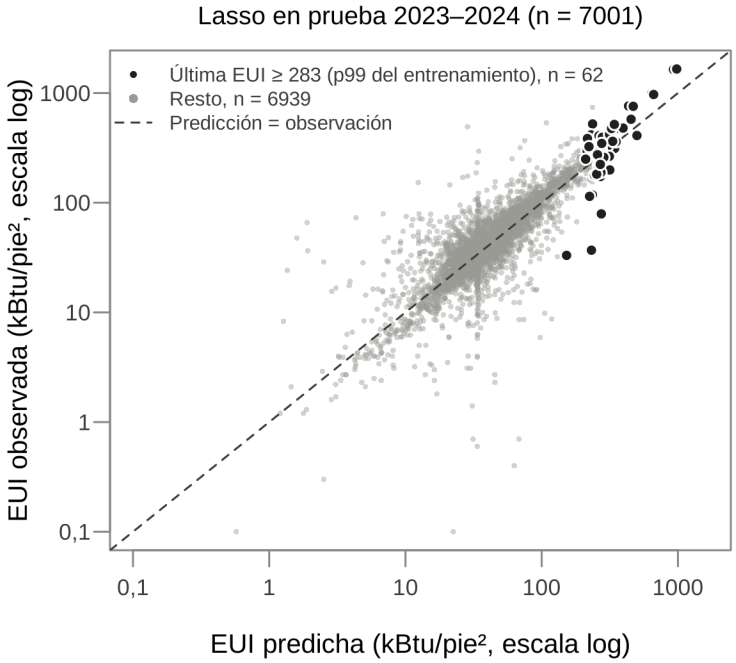


Figura 4: EUI observada frente a predicha por el lasso en la prueba, en escala logarítmica (kBtu/pie²). Los puntos negros son las 62 filas cuya última EUI supera el percentil 99 del entrenamiento (283 kBtu/pie²); la línea discontinua marca predicción igual a observación. La figura muestra dónde el modelo no es confiable: en consumos extremos la predicción queda bajo lo observado.

Error por edificio. Si cada edificio pesa lo mismo, el MAE es 10,08 para el lasso, 10,28 para la

referencia alternativa y 10,98 para la de la ficha. El error dividido por la mediana del tipo da el mismo orden (0,230, 0,241 y 0,255): el error típico equivale a casi un cuarto del nivel de su tipo.

5.4. Sensibilidades

Tabla 7: Sensibilidades en desarrollo (10 035 filas de validación; MAE en kBtu/pie²). S1 repite la búsqueda sin transformar la respuesta. S2 saca de todos los entrenamientos el 20 % de los edificios y muestra el cambio del MAE en esos edificios y en los demás. La última columna rehace la base sin la regla de errores de registro y evalúa en las mismas filas válidas.

Procedimiento	MAE base (log)	S1: MAE en escala original	S2: cambio, excluidos	S2: cambio, incluidos	Sin regla: MAE, mismas filas
Referencia	10,44	—	+0,01	0,00	12,18
Lasso	10,50	11,23	+0,14	+0,05	10,74
GAM	10,52	11,42	+0,29	+0,06	11,74
Bosque	10,52	11,27	+0,80	+0,09	10,55

S1, respuesta original frente a logarítmica (decisión de representación). Repetimos toda la búsqueda con la EUI sin transformar, y también la historia sin log, con las mismas ventanas, filas y presupuesto (Tabla 7). En escala original los tres procedimientos empeoran: el MAE reunido sube a 11,23 (lasso), 11,42 (GAM) y 11,27 (bosque), entre 0,7 y 0,9 sobre sus versiones en log. El RMSE del lasso y del GAM baja levemente (lasso: 24,0 frente a 24,7), como se espera al estimar la media condicional por mínimos cuadrados en lugar de la mediana, y el GAM G3 en escala original produce 2265 predicciones negativas. La conclusión no cambia: el lasso sigue siendo el de menor MAE, ningún modelo supera a la referencia y la escala log es la que corresponde a la métrica principal.

S2, edificios excluidos del ajuste (decisión de población y validación). Sacamos de todos los entrenamientos un 20 % de los edificios de desarrollo, elegido al azar con semilla fija (721 edificios, de los que 716 aparecen en validación), y comparamos en las mismas filas. Para esos edificios nuevos para el modelo, el MAE sube 0,14 en el lasso, 0,29 en el GAM y 0,80 en el bosque; en los demás sube menos de 0,1. La conclusión de desarrollo no cambia: sobre todas las filas, el lasso de esta corrida (MAE 10,57) sigue siendo el mejor de los tres, pero no supera a la referencia (10,44). El bosque depende más de haber visto al edificio, mientras el lasso, apoyado en la historia propia, se traslada mejor a edificios que el ajuste no conoce. Su ventaja en prueba (9,50) podría no repetirse con edificios nuevos.

Control de la regla de errores de registro. Sin la regla, en las mismas filas válidas, el MAE de la referencia sube de 10,44 a 12,18 y su RMSE de 24,0 a 175,7, porque los registros erróneos pasan a ser historia; el bosque casi no cambia. Si además se evalúan las 7 filas erróneas, el MAE de todos sube a 19,9–21,5 y el RMSE a cerca de 500: sin la regla, unas pocas filas dominarían la comparación.

6. Discusión

6.1. Respuesta a la pregunta

Con información hasta $a - 2$, la EUI anual de un edificio conocido se anticipa con un MAE cercano a 10 kBtu/pie², alrededor de un cuarto del nivel típico de su tipo. Casi toda la información útil está en la historia del propio edificio: cuando existe la EUI de $a - 2$, el lasso apenas mejora a la persistencia, y su ventaja frente a la referencia de la ficha viene de usar la última EUI cuando falta la de $a - 2$. Los

atributos del edificio ayudan sobre todo cuando no hay historia. Los coeficientes del lasso (Anexo A.2) son asociaciones predictivas condicionadas a las demás variables; con predictores correlacionados, como superficie, pisos y tipo, no deben leerse como efectos causales.

6.2. Utilidad y condiciones de uso

En desarrollo el lasso no superó a la referencia, y en prueba su ganancia frente a una persistencia bien construida, la referencia alternativa fijada antes de abrir la prueba, es de 0,15 kBtu/pie² con un intervalo que incluye el 0: una ganancia pequeña e incierta, que no justifica por sí sola la mayor complejidad. Como herramienta para el programa, sugerimos:

- **Con historia:** usar la última EUI reportada hasta $a-2$; el lasso rinde casi igual, es más complejo y es menos confiable en edificios grandes, hospitales, universidades y consumos extremos.
- **Sin historia:** usar el lasso, que mejora a la mediana del tipo en 1,3 kBtu/pie² (255 filas).
- **Consumo previo extremo** ($\geq$ 283 kBtu/pie²): no usar el lasso, que subestima.
- **Cada año:** reajustar con los nuevos reportes y revisar si hubo un choque común, porque ningún modelo entrenado con años anteriores lo anticipa.

Esta sugerencia proviene de comparaciones definidas antes de abrir la prueba, pero se apoya en dos años: no cambia el procedimiento elegido ni el resultado informado, y conviene confirmarla con años nuevos.

6.3. Límites de generalización

La evaluación es retrospectiva: usamos la versión descargada en 2026, que pudo corregir reportes antiguos, y atributos que la base repite con su valor actual. La población son edificios del programa con un reporte válido en el año objetivo; no sabemos cuánto erraríamos en edificios que no reportaron, y los edificios sin historia tienen errores mucho mayores (MAE de 15,3 en prueba). La prueba cubre dos años posteriores a la pandemia, y los intervalos son condicionales a los ajustes: no incluyen la variación entre años, que en desarrollo cambió el signo de las diferencias. Los umbrales de la regla de calidad son una decisión; el control de la sección 5.4 muestra su efecto.

6.4. Errores detectados y su corrección

- **Regla de selección con ventanas dependientes.** El plan inicial usaba la regla de un error estándar, con el error estándar calculado como la desviación estándar de los tres MAE dividida por $\sqrt{3}$. Las ventanas comparten edificios y datos de entrenamiento, y los choques por año inflan esa desviación; con ella se elegía un lasso mucho más penalizado (λ = 0,03284, MAE 10,94). Lo corregimos antes de abrir la prueba con la regla del menor MAE reunido (EYP3407, 2026: clase S10 y enunciado 4.3), y el lasso elegido pasó a λ = 0,005332.
- **Orden de categorías dependiente del idioma.** El orden alfabético de R depende de la configuración regional y define la categoría base del lasso, así que en otro computador el ajuste podía cambiar. Lo detectamos después de evaluar la prueba y fijamos el orden en `analisis.R` (`LC_COLLATE = C`). Todas las tablas y predicciones de las secciones 1 a 3 salieron idénticas byte a byte: los resultados no cambiaron.
- **Tiempos dentro de una tabla de resultados.** Una columna de segundos impedía comprobar la reproducción byte a byte; la movimos a `tiempos_busqueda.csv` antes de la prueba.

- **Fuga, prueba y duplicados.** Ninguna verificación encontró fuga (sección 3.2), la prueba se evaluó una sola vez con decisiones congeladas, la clave edificio–año es única y cada exclusión está documentada con su efecto.

7. Reproducibilidad y contribuciones

- **Comando:** `Rscript --vanilla analisis.R`, desde la raíz del repositorio y con el paquete de datos descomprimido en `datos/`. Ejecuta la preparación, las particiones, el ajuste, la evaluación, las figuras y este informe.
- **Versión del repositorio:** commit `f432037` (con cambios sin confirmar en el código). Enlace: [completar con el enlace público].
- **Entradas:** `caso04_seattle_edificios.zip`, descomprimido en `datos/` con sus tres archivos: `datos.csv`, `diccionario.csv` y `LEEME.txt`.
- **Huella de la entrada:** md5 de `datos.csv`, bc623281c6ad5a50017d5f0d8e2a3b1a.
- **Entorno y tiempo:** R 4.3.3 (R Core Team, 2026) en Ubuntu 24.04.5 LTS, 4 núcleos; el análisis tomó 4,2 minutos, más la generación de este informe. Paquetes: dplyr 1.2.1, glmnet sin dato, mgcv 1.9-4, ranger sin dato, rmarkdown 2.31, knitr 1.51. Semilla 3407 para el bosque, el remuestreo y la muestra de S2; los modelos usan un núcleo.
- **Salidas:** tablas, predicciones y figuras en `resultados/`; las decisiones congeladas antes de la prueba y su registro de cambios, en `CONGELADO.md`; la prueba desde una copia limpia, en `README.md`.
- **Contribuciones:** [completar con la síntesis de los aportes de cada integrante].
- **Declaración de uso de IA:** [pendiente].

Referencias

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.

City of Seattle, Office of Sustainability and Environment (2026). *Building Energy Benchmarking Data, 2015-Present* [conjunto de datos `teqw-tu6e`, dominio público]. Portal de datos abiertos de Seattle, https://data.seattle.gov. Copia con los registros 2015–2024 preparada para el curso el 12 de octubre de 2026.

Davison, A. C. y Hinkley, D. V. (1997). *Bootstrap Methods and their Application*. Cambridge University Press.

EYP3407 (2026). *Proyecto aplicado: enunciado, ficha del caso 04 y rúbrica*; *Clase S10: selección de variables*. Pontificia Universidad Católica de Chile.

Friedman, J., Hastie, T. y Tibshirani, R. (2010). Regularization paths for generalized linear models via coordinate descent. *Journal of Statistical Software*, 33(1), 1–22.

Hyndman, R. J. y Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3.ª ed.). OTexts.

James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in R* (2.ª ed.). Springer.

R Core Team (2026). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Viena.

Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B*, 58(1), 267–288.

Wood, S. N. (2011). Fast stable restricted maximum likelihood and marginal likelihood estimation of semiparametric generalized linear models. *Journal of the Royal Statistical Society: Series B*, 73(1), 3–36.

Wood, S. N. (2017). *Generalized Additive Models: An Introduction with R* (2.ª ed.). Chapman and Hall/CRC.

Wright, M. N. y Ziegler, A. (2017). ranger: A fast implementation of random forests for high dimensional data in C++ and R. *Journal of Statistical Software*, 77(1), 1–17.

A. Anexo técnico

A.1. Búsqueda completa en desarrollo

Tabla 8: Las 35 configuraciones evaluadas en las tres ventanas (10 035 filas). MAE y RMSE reunidos en kBtu/pie². Lasso en orden de penalización decreciente; GAM de G1 a G3; bosque ordenado por MAE.

Familia	Configuración	MAE	RMSE	MAE 2019	MAE 2020	MAE 2021
Lasso	$\lambda = 0{,}6019$	25,61	55,7	26,78	23,40	26,77
Lasso	$\lambda = 0{,}4184$	20,72	49,5	21,69	18,56	22,05
Lasso	$\lambda = 0{,}2909$	17,22	43,5	17,95	15,27	18,58
Lasso	$\lambda = 0{,}2022$	14,77	38,1	15,26	13,04	16,15
Lasso	$\lambda = 0{,}1406$	13,14	33,8	13,38	11,66	14,49
Lasso	$\lambda = 0{,}09774$	12,14	30,7	12,17	10,92	13,43
Lasso	$\lambda = 0{,}06795$	11,52	28,5	11,41	10,51	12,76
Lasso	$\lambda = 0{,}04724$	11,15	27,1	10,92	10,30	12,34
Lasso	$\lambda = 0{,}03284$	10,94	26,1	10,64	10,20	12,07
Lasso	$\lambda = 0{,}02283$	10,78	25,6	10,45	10,07	11,92
Lasso	$\lambda = 0{,}01587$	10,65	25,2	10,31	9,92	11,81
Lasso	$\lambda = 0{,}01103$	10,56	24,9	10,24	9,83	11,70
Lasso	$\lambda = 0{,}00767$	10,51	24,8	10,22	9,77	11,64
Lasso	$\lambda = 0{,}005332$ (elegida)	10,50	24,7	10,20	9,76	11,64
Lasso	$\lambda = 0{,}003707$	10,52	24,7	10,20	9,78	11,67
Lasso	$\lambda = 0{,}002577$	10,54	24,7	10,21	9,80	11,69
Lasso	$\lambda = 0{,}001791$	10,55	24,7	10,25	9,81	11,71
Lasso	$\lambda = 0{,}001245$	10,57	24,8	10,28	9,81	11,73
Lasso	$\lambda = 0{,}0008658$	10,59	24,8	10,30	9,83	11,75
Lasso	$\lambda = 0{,}0006019$	10,61	24,8	10,32	9,85	11,75
GAM	G1 (elegida)	10,52	24,5	10,13	10,14	11,35
GAM	G2	10,79	24,9	10,51	10,33	11,59
GAM	G3	10,54	24,5	10,21	9,97	11,53
Bosque	mtry 5, nodo 5 (elegida)	10,52	24,6	9,75	10,19	11,73
Bosque	mtry 8, nodo 5	10,55	24,2	9,80	10,21	11,74
Bosque	mtry 8, nodo 20	10,58	25,5	9,85	10,21	11,78
Bosque	mtry 3, nodo 5	10,60	25,9	9,85	10,20	11,84
Bosque	mtry 5, nodo 20	10,62	26,6	9,90	10,25	11,82
Bosque	mtry 8, nodo 50	10,64	27,1	10,02	10,19	11,81
Bosque	mtry 12, nodo 50	10,68	26,5	10,05	10,23	11,86
Bosque	mtry 12, nodo 20	10,69	25,5	9,92	10,31	11,92
Bosque	mtry 12, nodo 5	10,69	24,3	9,96	10,31	11,90
Bosque	mtry 5, nodo 50	10,73	28,7	10,09	10,37	11,81
Bosque	mtry 3, nodo 20	10,82	28,8	10,20	10,44	11,90
Bosque	mtry 3, nodo 50	11,17	31,5	10,60	10,76	12,23

A.2. Coeficientes del lasso final

Tabla 9: Coeficientes distintos de 0 del lasso ajustado con los objetivos 2017–2021 ($\lambda = 0{,}005332$), en escala de log(EUI) y en las unidades originales de cada predictor (glmnet estandariza los predictores para penalizar, pero entrega los coeficientes en sus unidades). Cada indicadora de categoría se compara con la categoría base de su variable. Son asociaciones predictivas, no efectos causales.

Variable	Coeficiente	Variable	Coeficiente
Constante	0,462	Uso: Office	−0,0003
log(última EUI válida hasta $a-2$)	0,674	Uso: Other	0,012
log(EUI de $a-3$)	0,187	Uso: Otro	0,057
Falta la EUI de $a-3$	0,079	Uso: Self-Storage Facility	−0,100
log(superficie)	0,001	Uso: Senior Living Community	0,012
Fracción de estacionamiento	0,018	Uso: Sin dato	−0,142
log(número de edificios)	0,005	Uso: Supermarket/Grocery Store	0,162
Tipo: University	0,071	Uso: Vehicle Repair Services	0,020
Uso: Distribution Center	−0,015	Barrio: EAST	0,011
Uso: Hospital (General Medical & Surgical)	0,224	Barrio: GREATER DUWAMISH	−0,001
Uso: Hotel	−0,004	Barrio: LAKE UNION	0,017
Uso: K-12 School	0,008	Barrio: MAGNOLIA / QUEEN ANNE	−0,0004
Uso: Laboratory	0,209	Barrio: NORTH	−0,018
Uso: Medical Office	0,086	Barrio: NORTHEAST	0,005
Uso: Non-Refrigerated Warehouse	−0,015		

A.3. Datos por año y distribución de la respuesta

Tabla 10: Registros por año, respuestas faltantes, altas y bajas de edificios respecto del año anterior (2015–2022, sin mirar la prueba) y filas objetivo válidas según la historia disponible (2017–2021 y 2023–2024).

Año	Filas	Sin respuesta	Altas	Bajas	Objetivo: EUI en $a-2$	Solo historia anterior	Sin historia
2015	3175	33	—	—	—	—	—
2016	3253	45	84	6	—	—	—
2017	3310	37	61	4	3109	0	164
2018	3381	39	84	13	3166	12	164
2019	3456	46	89	14	3214	20	175
2020	3530	57	93	19	3266	25	178
2021	3578	419	56	8	3000	30	127
2022	3617	345	50	11	—	—	—
2023	—	—	—	—	3012	361	123
2024	—	—	—	—	3103	270	132

Tabla 11: Distribución de la respuesta en las 16 650 filas de desarrollo.

Escala	Mín.	p1	p25	Mediana	p75	p99	Máx.	Media
EUI (kBtu/pie²)	0,10	5,80	27,60	37,20	57,60	283,46	1538,10	52,46
log(EUI)	−2,30	1,76	3,32	3,62	4,05	5,65	7,34	3,70

A.4. Auditoría de columnas

Tabla 12: Columnas no clave en 2015–2022: número de edificios en que el valor cambia entre años (0 indica un valor actual copiado a todos los años) y porcentaje de filas faltantes. Hay 3692 edificios en esos años.

Columna	Cambios	Faltante	Columna	Cambios	Faltante
buildingname	0	0,0 %	siteeui_kbtu_sf	3627	3,7 %
buildingtype	0	0,0 %	siteenergyuse_kbtu	3627	3,7 %
taxparcelidentificationnumber	0	0,0 %	siteenergyusewn_kbtu	3624	4,8 %
address	0	0,0 %	sourceeuiwn_kbtu_sf	3623	4,8 %
city	0	0,0 %	sourceeui_kbtu_sf	3627	3,7 %
state	0	0,0 %	epapropertytype	364	0,0 %
zipcode	0	0,0 %	largestpropertyusetype	331	0,0 %
latitude	0	0,0 %	largestpropertyusetypegfa	1613	0,0 %
longitude	0	0,0 %	secondlargestpropertyusetype	513	40,4 %
neighborhood	0	0,0 %	secondlargestpropertyuse	879	45,5 %
councildistrictcode	0	0,0 %	thirdlargestpropertyusetype	384	75,4 %
yearbuilt	0	0,0 %	thirdlargestpropertyusetypegfa	433	78,2 %
numberoffloors	0	0,0 %	electricity_kwh	3627	2,9 %
numberofbuildings	0	0,0 %	steamuse_kbtu	136	96,5 %
propertygfatotal	0	0,0 %	naturalgas_therms	2484	39,1 %
propertygfabuildings	0	0,0 %	compliancestatus	1236	0,0 %
propertygfaparking	0	0,0 %	complianceissue	1230	1,7 %
selfreportgfatotal	0	0,0 %	electricity_kbtu	3627	2,9 %
selfreportgfabuildings	0	0,0 %	naturalgas_kbtu	2484	39,1 %
selfreportparking	0	0,0 %	totalghgemissions	3628	2,6 %
energystarscore	2997	26,9 %	ghgemissionsintensity	3541	4,6 %
siteeuiwn_kbtu_sf	3623	4,8 %	demolished	0	0,0 %

A.5. Errores de registro y saltos grandes

Tabla 13: Registros de 2015–2022 marcados por la regla (EUI > 10 veces la mediana previa del edificio y > 1000 kBtu/pie²). Otros 18 saltos de más de 10 veces no se marcan porque su nivel es posible.

Edificio	Año	Tipo	EUI	Mediana previa	Veces
50239	2021	Multifamily HR (10+)	42 480,2	23,5	1808
755	2019	NonResidential	17 488,5	71,8	244
755	2020	NonResidential	17 549,6	72,9	241
25042	2022	NonResidential	6389,5	42,8	149
49967	2020	University	6702,9	116,9	57
23689	2021	NonResidential	1952,2	40,7	48
503	2020	NonResidential	3742,4	111,7	34
23120	2022	NonResidential	2544,8	110,5	23
27162	2020	NonResidential	4462,8	286,1	16

A.6. Supuestos y estabilidad

Tabla 14: Residuo en log (log de la EUI observada menos la predicción en log) dentro del entrenamiento de cada ventana (bosque: fuera de bolsa) y en su año de validación, y número de coeficientes del lasso distintos de 0.

Modelo	Ventana	Mediana en entrenamiento	Mediana fuera de muestra	Media fuera de muestra	Coef. lasso no nulos
Lasso	2019	0,006	−0,099	−0,097	21
Lasso	2020	0,007	−0,044	−0,081	24
Lasso	2021	0,003	−0,009	−0,046	25
GAM	2019	0,008	−0,095	−0,097	—
GAM	2020	0,009	−0,058	−0,098	—
GAM	2021	0,008	−0,017	−0,062	—
Bosque	2019	0,009	−0,058	−0,067	—
Bosque	2020	0,012	−0,047	−0,085	—
Bosque	2021	0,010	−0,007	−0,053	—

A.7. Cambio respecto de $a-2$ por tipo de edificio

Tabla 15: Mediana del cambio log(EUI de a / EUI de $a-2$) por tipo de edificio y año objetivo, en los edificios con ambos valores.

Tipo	2017	2018	2019	2020	2021	2023	2024
Hospital	0,026	0,001	−0,056	−0,024	−0,002	−0,016	−0,046
Multifamiliar, 10 o más pisos	0,076	−0,006	−0,053	−0,015	−0,008	−0,022	−0,067
Multifamiliar, 1 a 4 pisos	0,063	−0,004	−0,044	0,008	0,015	−0,009	−0,060
Multifamiliar, 5 a 9 pisos	0,060	0,000	−0,037	0,000	0,000	0,007	−0,040
No residencial	0,049	−0,010	−0,054	−0,138	−0,096	0,010	−0,061
Escuela	0,100	−0,062	−0,059	−0,079	0,186	−0,104	−0,173
Universidad	0,084	0,027	−0,037	−0,062	−0,017	0,042	−0,051

A.8. Error por uso principal en prueba

Tabla 16: MAE en prueba (kBtu/pie^2) por uso principal del último registro $\leq a-2$. Conservan su nombre los usos con al menos 300 filas en el entrenamiento final, una regla que no mira la prueba; «Otros usos» reúne los demás. Mismas filas para todos los procedimientos en cada grupo.

Grupo	n	Ref.	Ref. alt.	Lasso	GAM	Bosque	Lasso − ref. alt.
Vivienda multifamiliar	3672	6,75	6,61	5,60	6,05	5,41	−1,01
Oficinas	963	9,26	9,15	9,26	8,78	9,29	+0,11
Bodega no refrigerada	297	11,88	11,16	10,12	10,31	10,51	−1,04
Escuela (K-12)	279	10,56	10,64	7,35	8,99	7,35	−3,28
Hotel	151	14,19	13,56	17,03	16,36	18,47	+3,47
Comercio minorista	143	12,98	12,49	13,57	13,23	14,08	+1,08
Lugar de culto	112	8,98	7,88	6,48	6,84	6,38	−1,41
«Other» de la fuente	96	18,24	16,74	18,20	16,71	17,23	+1,46
Otros usos	1056	22,75	19,35	22,66	21,19	20,57	+3,31
Sin registro de uso $\leq a-2$	232	16,94	16,94	15,29	15,32	15,72	−1,66

A.9. Mayores errores del lasso en prueba

Tabla 17: Las diez filas de prueba con mayor error absoluto del lasso (EUI en kBtu/pie²).

Edificio	Año	Uso previo	Última EUI	Observada	Lasso	Referencia
49780	2023	Data Center	1538,1	1639,7	927,3	1538,1
49780	2024	Data Center	1632,7	1656,5	979,6	1632,7
22479	2024	Supermarket/Grocery Store	282,8	740,9	236,5	282,8
24202	2024	Distribution Center	29,6	494,1	28,5	29,6
49967	2024	College/University	119,5	536,1	108,0	119,5
365	2023	Data Center	909,9	989,2	641,3	909,9
753	2023	Data Center	630,8	761,4	434,1	49,8
365	2024	Data Center	956,7	969,8	663,2	956,7
95	2024	Hotel	87,0	367,5	75,1	49,8
753	2024	Data Center	630,8	756,4	469,8	49,8