PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
FACULTAD DE MATEMÁTICAS
DEPARTAMENTO DE ESTADÍSTICA

INTENSIDAD ENERGÉTICA ANUAL DE EDIFICIOS DE SEATTLE: ¿CUÁNTO SE PUEDE ANTICIPAR CON INFORMACIÓN HASTA DOS AÑOS ANTES?

EYP3407 Tópicos Aplicados en Estadística · Proyecto aplicado, caso 04

Grupo 4

Integrantes:
Juan Pablo Cuevas, Cristóbal Honorato, Michelle Houngbo, Maximiliano León

Fecha de entrega: 10 de noviembre de 2026



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
FACULTAD DE MATEMÁTICAS
DEPARTAMENTO DE ESTADÍSTICA

1. Resumen ejecutivo

El programa de reporte energético de Seattle recibe cada año la intensidad energética (EUI, en kBtu/pie²) de más de 3000 edificios, pero en enero del año a el reporte de $a-1$ todavía está incompleto. Evaluamos qué tan bien se puede anticipar la EUI anual de un edificio conocido usando solo información hasta $a-2$.

Con los años de validación 2019–2021, ningún modelo superó a la referencia de la ficha, que repite la EUI de $a-2$. Entre los tres procedimientos elegimos un lasso sobre log(EUI), el de menor error. En la prueba 2023–2024, el lasso se equivocó en promedio en 9,86 kBtu/pie², 0,84 menos que la referencia (IC 95 %: $[-1{,}40;\ -0{,}23]$). Sin embargo, casi toda esa ventaja (0,69) viene de 631 casos sin dato en $a-2$: ahí la referencia usa la mediana del tipo de edificio, mientras el lasso usa el último dato del edificio. Si la referencia también usa ese último dato, la diferencia baja a $-0{,}15$ kBtu/pie² y el intervalo $[-0{,}63;\ 0{,}38]$ incluye el 0: no hay mejora clara.

Recomendamos predecir la EUI con el último dato reportado por el propio edificio. El lasso sirve sobre todo para edificios sin historia, y no conviene usarlo en edificios de consumo muy alto ($\geq$ 283 kBtu/pie²), porque lo subestima. La principal limitación es que la prueba cubre solo dos años, y choques comunes a todos los edificios, como la pandemia, pueden cambiar los resultados de un año a otro.

2. Problema y datos

2.1. Pregunta y uso

La pregunta planteada es si se puede anticipar la intensidad energética anual de un edificio ya conocido a partir de sus características (tipo, tamaño, uso) y de lo que reportó en años anteriores (EYP3407, 2026). Un modelo que responda lo anterior sería útil para quien administra el programa de reporte, pues al comenzar el año necesita una estimación para cada edificio, por ejemplo para decidir a cuáles hacer seguimiento, sin esperar el reporte de $a-1$, que todavía está incompleto.

Para evaluar el modelo simulamos cómo se habría usado en el pasado. Para predecir, por ejemplo, la EUI de 2019, solo usamos los reportes hasta 2017. El problema es que solo tenemos la base descargada en 2026, no la que existía en enero de 2019. Por eso suponemos que los reportes hasta 2017 que vemos hoy son iguales a los que se conocían en esa fecha. Si alguno se corrigió después, el modelo usó un dato algo mejor que el disponible en su momento, y la evaluación resulta un poco optimista (sección 3.2).

2.2. Población, unidad y respuesta

Una fila es un edificio–año objetivo, con clave `osebuildingid` y `datayear`, que el código verifica que no se repite. La respuesta es `siteeui_kbtu_sf`, la energía consumida en el sitio durante el año dividida por la superficie bruta. Se utiliza cada edificio con un reporte válido en el año objetivo, tenga o no historia y aunque deje de reportar después. Por otro lado, las filas sin respuesta se excluyen y no se imputan. Por ende, las conclusiones valen para los edificios del programa que reportan, no para los que dejaron de hacerlo.

2.3. Procedencia

Los datos provienen del programa *Seattle Building Energy Benchmarking*, que la ciudad publica como *Building Energy Benchmarking Data, 2015-Present* (conjunto `teqw-tu6e`; City of Seattle, 2026). Según los metadatos del portal, consultados el 9 de noviembre de 2026, son de dominio público. Usamos la copia del curso, `caso04_seattle_edificios.zip`, preparada el 12 de octubre de 2026, cuyo `datos.csv` tiene 34 699 registros

edificio–año de 3823 edificios y 46 columnas. Los archivos originales no se editan, cualquier filtro y transformación está en el código. Como solo tenemos la versión descargada, un valor antiguo puede incluir correcciones posteriores.

2.4. Construcción de la muestra

Tabla 1
Construcción de la muestra. Desarrollo: objetivos 2017–2021, de los que se evalúan 2019–2021 (2017 y 2018 solo entrenan). Prueba: objetivos 2023–2024.

Paso	Desarrollo: filas	Desarrollo: edificios	Prueba: filas	Prueba: edificios
Filas objetivo del período	17 255	3632	7399	3749
Con respuesta (EUI del año)	16 657	3607	7006	3640
Sin errores de registro	16 650	3607	7001	3638
Filas evaluadas	10 035	3575	7001	3638

Como cada predicción usa información hasta dos años antes, los años 2015, 2016 y 2022 no se predicen, solo aportan historia. Los años objetivo de desarrollo son 2017–2021 y los de prueba, 2023–2024 (Tabla 1 y Figura 1). En ambos excluimos las filas sin EUI del año (598 en desarrollo y 393 en prueba) y las marcadas como error de registro (7 y 5; sección 2.5).

No todas las filas tienen la EUI de $a-2$, porque cada año entran edificios nuevos (entre 50 y 93) y otros no reportan algún año. Esto pesa mucho más en la prueba, pues en 2021 y 2022 faltan 419 y 345 respuestas, frente a 33–57 por año antes de 2021. Por eso, 631 filas de prueba (9,0 %) solo tienen historia anterior a $a-2$, contra 75 (0,7 %) en desarrollo. A las 24 654 filas objetivo (3813 edificios) se unen la EUI de $a-2$ y la de $a-3$ por la clave edificio–año, de uno a uno, y la última EUI válida y el uso por el registro más reciente $\leq a-2$ del mismo edificio, de muchos a uno (858 filas comparten así su última EUI). Cada unión conserva filas y edificios (`resultados/uniones.csv`).

2.5. Calidad de los datos

Primero revisamos si las características de cada edificio cambian de un año a otro. De las 44 columnas que no son clave, 21 tienen exactamente el mismo valor en todos los años de un mismo edificio (2015–2022), entre ellas el tipo, el año de construcción, los pisos, las superficies, el barrio y las coordenadas. Esto indica que la base no guarda cómo era el edificio en cada año, sino que repite su valor actual. Usamos estas variables suponiendo que esas características no cambiaron en el período. Por otro lado, el uso principal sí cambia en 331 edificios, por lo que para predecir el año a usamos el uso del último registro hasta $a-2$. También comprobamos que ningún edificio aparece con dos identificadores distintos (Anexo A.4).

Hay 66 filas con 0 pisos y 284 con 0 edificios, las cuales tratamos como dato faltante. Como medida de tamaño usamos la superficie confirmada por la ciudad, siempre positiva e igual a la de los edificios más el estacionamiento, y no la autodeclarada, que difiere en más de 10 % en 1034 edificios. En el entrenamiento final, 33 de las 61 categorías de uso principal tienen menos de 30 filas y se agrupan en «Otro» (2,1 % de las filas).

Para separar errores de registro de consumos extremos válidos fijamos, antes de ajustar modelos, una regla que solo mira años anteriores. Un registro es error si su EUI supera 10 veces la mediana de las EUI previas del mismo edificio y además supera 1000 kBtu/pie², como ocurre con un error de unidades. La regla marca 9 registros en 2015–2022 (por ejemplo, 42 480 con una mediana previa de 23,5; Anexo A.5) y 5 en 2023–2024, que no se usan como objetivo ni como historia. Las caídas no se marcan, porque un edificio puede vaciarse, y los consumos altos con una historia coherente se conservan, por ejemplo, el mayor valor de desarrollo, 1538 kBtu/pie², es de un centro de datos que reportaba 1167 dos años antes.

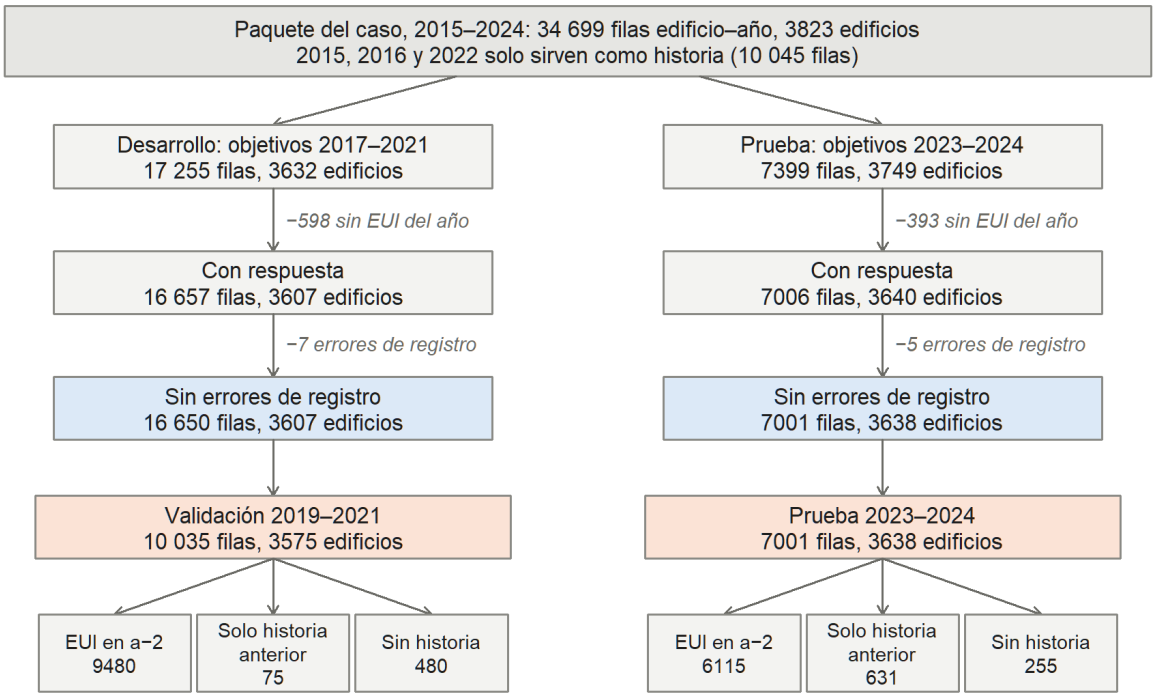


Figura 1
Construcción de la muestra en desarrollo (izquierda) y prueba (derecha), en filas edificio–año y edificios. En azul, los objetivos válidos; en naranja, las filas evaluadas, separadas según la historia disponible al predecir. Las filas que solo tienen historia anterior a $a-2$ pasan de 75 en desarrollo a 631 en prueba, lo que explica buena parte de los resultados de la sección 5.2.

2.6. Descripción de la respuesta

Antes de modelar, describimos la respuesta en las 16 650 filas de desarrollo que quedan tras excluir los errores de registro (Tabla 1). Su distribución es muy asimétrica, pues la mediana es 37,2 kBtu/pie², pero el percentil 99 llega a 283 y el máximo a 1538. Por lo anterior, se decidió realizar la transformación a log(EUI). Como todos los valores son positivos (mínimo 0,1), el logaritmo está definido, y con él la asimetría baja de 7,3 a −0,1. Además, en escala log una diferencia equivale a un cambio proporcional (una diferencia de 0,1 corresponde aproximadamente a un 10 %), lo que facilita su interpretación.

Otro hallazgo es que la mayor parte de la variación está entre edificios y no dentro de un mismo edificio: la media de cada edificio explica el 86,5 % de la variación de log(EUI) en 2015–2022. Además, la EUI de un edificio se parece mucho a la que tenía dos años antes, como muestra la correlación de Spearman entre ambas, que va de 0,91 en 2017 a 0,85 en 2021. Por eso, la historia del propio edificio es el predictor principal.

Por último, el cambio respecto de $a-2$ crece con el nivel del edificio si se mide en kBtu/pie² (correlación de Spearman entre nivel y cambio absoluto: 0,47), pero casi no depende de él si se mide en log (0,07). Es decir, los edificios cambian en proporción a su consumo, lo que respalda modelar la EUI en escala logarítmica (Anexo A.3). El análisis de sensibilidad S1, que repite la búsqueda de modelos sin el logaritmo, lo confirma (sección 5.4). Las predicciones se devuelven a kBtu/pie² con la función exponencial (sección 4.1).

2.7. Variables admisibles y excluidas

La Tabla 2 resume qué columnas pueden usarse al predecir. El criterio es que solo entra información conocida dos años antes del año objetivo. Se excluyen las columnas que contienen la respuesta, las que se registran después y las que solo identifican al edificio o repiten otra variable.

Tabla 2
Variables usadas y excluidas, agrupadas por decisión. «Valor actual»: la base repite en todos los años el valor vigente del edificio (Anexo A.4).

Grupo	Columnas	Cómo entran o por qué se excluyen
Usadas: características del edificio	Barrio, tipo, año de construcción, pisos, edificios de la propiedad, superficie total y de estacionamiento	Valor actual. Entran como barrio, tipo, antigüedad, log de pisos, log de edificios, log de la superficie y fracción de estacionamiento.
Usadas: usos del edificio	Usos 1.º a 3.º y sus superficies	Último registro $\leq a-2$. Entran como uso principal, fracción de superficie de ese uso y número de usos.
Usadas: historia de la respuesta	EUI de los años $\leq a-2$	Log de la última EUI válida y de la EUI de $a-3$, con indicadoras.
Excluidas por fuga	13 medidas del año objetivo: consumo, emisiones y ENERGY STAR	Contienen la respuesta; sus valores pasados repetirían la historia de la EUI.
Excluidas por conocerse después	Distrito del concejo, cumplimiento del reporte y demolición	Usan límites de 2023, el cierre del reporte o el ciclo 2023.
Excluidas por identificar o repetir	Identificador y año (clave edificio–año), nombre, dirección, parcela y coordenadas; superficie de edificios y superficies autodeclaradas; tipo de propiedad EPA	Identifican al edificio (la ubicación entra como barrio) o repiten otra variable (sección 2.5).

3. Diseño de evaluación

3.1. Particiones temporales

Como el objetivo es predecir años futuros de edificios ya conocidos, la partición debe entrenar con el pasado y validar después (EYP3407, 2026, sesión S03; Hyndman y Athanasopoulos, 2021). Usamos tres ventanas que crecen y validan 2019, 2020 y 2021 (Figura 2). Para validar el año a solo se entrena con objetivos hasta $a-2$, porque las respuestas de $a-1$ tampoco estarían disponibles al predecir. Un mismo edificio aparece en entrenamiento y en validación, tal como ocurrirá al usar el modelo. Para medir cuánto ayuda eso, el análisis de sensibilidad S2 (sección 5.4) saca del entrenamiento un 20 % de los edificios y los evalúa como si fueran nuevos. Después de elegir, el procedimiento se reajusta con los objetivos 2017–2021 y se evalúa una sola vez en 2023 y 2024.

3.2. Información disponible

Cada predictor se construye con registros de años $\leq a-2$, tanto en las filas evaluadas como en las de entrenamiento, y el código se detiene si alguna variable de historia viene de un año posterior. Además, hicimos una prueba de fuga (`verificacion/fuga.R`): cambiamos al azar la EUI y los usos de los años posteriores a cada corte y volvimos a predecir. Si el código usara información del futuro, las predicciones habrían cambiado, pero no cambió ninguna, ni en las 35 configuraciones ni en la referencia ni en la prueba. Si la ciudad corrigió reportes antiguos después de entregarlos, nuestra base es más limpia que la disponible en su momento y la evaluación resulta algo optimista.

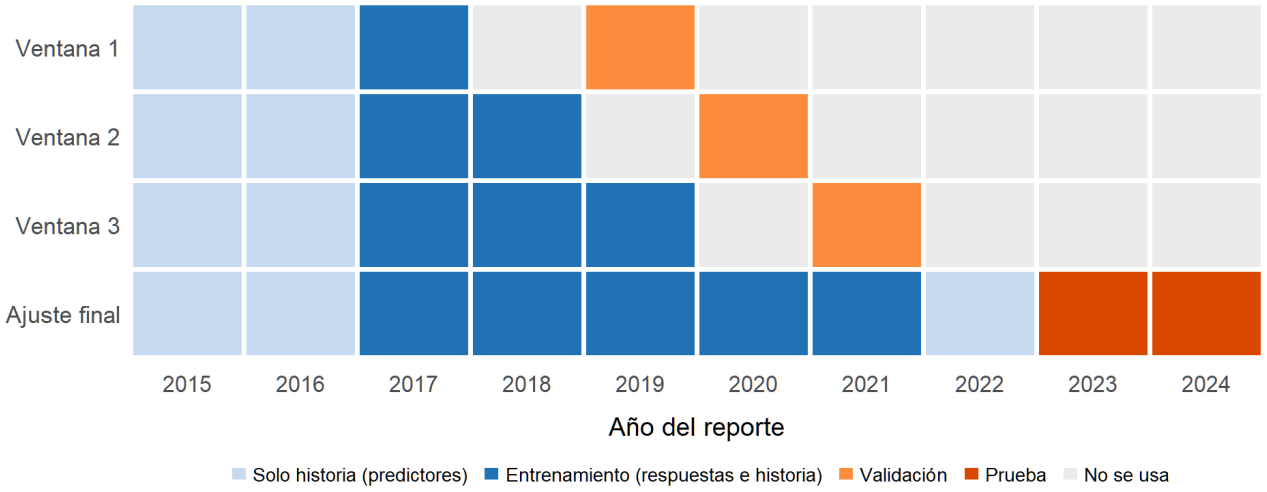


Figura 2
Diseño temporal de la evaluación. Cada fila es un ajuste y cada casilla, un año del reporte. En el ajuste final, 2022 solo aporta historia para predecir 2024.

3.3. Métricas, referencia y regla de selección

La métrica principal es el MAE en kBtu/pie², calculado sobre las filas reunidas de las tres ventanas, y el RMSE se informa como complemento porque es sensible a pocos errores grandes. Como un mismo edificio aparece varios años, en prueba también informamos el MAE por edificio, en que cada edificio pesa lo mismo, y el error dividido por la mediana de su tipo, para comparar tipos con niveles de consumo distintos. Todos los procedimientos se evalúan en las mismas filas.

La referencia es predecir con la EUI de $a-2$ o, si ese año falta, con la mediana del tipo en el entrenamiento. Para los casos en que falta $a-2$ pero hay años anteriores, antes de abrir la prueba fijamos también una referencia alternativa que usa la última EUI válida hasta $a-2$. La informamos como comparación, pero no interviene en la selección. Para elegir el procedimiento, dentro de cada familia y entre familias, usamos el menor MAE reunido.

3.4. Congelamiento e incertidumbre

Antes de evaluar la prueba registramos en `CONGELADO.md` la población, la regla de calidad, las variables, los modelos, la búsqueda, la métrica, la regla de selección y el procedimiento elegido, con fecha y huella md5 del código. Para la incertidumbre remuestreamos edificios con reposición (2000 réplicas; EYP3407, 2026, sesión S03; Davison y Hinkley, 1997), de modo que cada edificio aporta todas sus filas a la vez y se respeta la dependencia entre sus años. Como las predicciones quedan fijas, el intervalo de percentiles 95 % de la diferencia de MAE es condicional a los ajustes y no incluye la variación por choques comunes a un año, que examinamos comparando años (sección 5.3). La dispersión entre ventanas no se interpreta como un intervalo, porque las ventanas comparten datos.

4. Métodos

4.1. Preprocesamiento común

Todo lo que se estima en la preparación (medianas, categorías agrupadas, escalas) se calcula con el entrenamiento de cada ventana y se aplica sin recalcular a validación y prueba, para evitar fuga de información (EYP3407, 2026,

sesión S02).

- **Respuesta:** log(EUI).
- **Historia:** log de la última EUI válida hasta $a-2$ (si no hay, la mediana del entrenamiento, con indicadora), indicadora de historia antigua y log de la EUI de $a-3$ (si falta, se repite la última, con indicadora).
- **Uso** (último registro $\leq a-2$): uso principal, fracción de superficie del uso principal y número de usos, con indicadora de faltante.
- **Edificio:** log de la superficie, fracción de estacionamiento, antigüedad, log de pisos, log del número de edificios, tipo y barrio.
- **Categorías:** las de menos de 30 filas de entrenamiento pasan a «Otro»; un valor ausente, a «Sin dato».

Son 16 predictores, que suman en promedio 49 columnas al convertir las variables categóricas en indicadoras. Los modelos se ajustan sobre log(EUI) y predicen con exp(). Si el residuo en log tiene mediana 0, exp() de la predicción es la mediana condicional de la EUI, que es justamente la predicción que minimiza el error absoluto esperado y, por tanto, la que corresponde al MAE. Este supuesto se revisa en la sección 5.1.

4.2. Procedimientos y expectativas

Comparamos tres familias vistas en el curso, de flexibilidad creciente (EYP3407, 2026, sesiones S11, S14, S15, S16 y S22; James et al., 2021). Las expectativas se escribieron antes de ajustar:

- **M1, lasso** (Tibshirani, 1996; glmnet, Friedman et al., 2010): persistencia en escala log, porque la historia entra de forma lineal, más ajustes aditivos por tipo, uso, tamaño y barrio, con selección de variables por la penalización. Puede fallar si los efectos no son lineales en log o si cambian según el tipo.
- **M2, GAM** (Wood, 2017; mgcv): agrega curvas suaves para la historia, el tamaño y la antigüedad, con suavidad elegida por REML (Wood, 2011). No captura interacciones, y la historia de $a-2$ y la de $a-3$ juntas pueden generar concurvidad.
- **M3, bosque aleatorio** (Breiman, 2001; ranger, Wright y Ziegler, 2017): capta interacciones, como tipo × historia, sin especificarlas. No extrapola fuera del rango visto y puede apoyarse en reconocer edificios ya vistos.

4.3. Búsqueda de hiperparámetros y costo

Para el lasso probamos 20 valores de λ en escala logarítmica, desde el que anula todos los coeficientes (0,6019) hasta su milésima parte (EYP3407, 2026, sesión S12). Para el GAM, tres fórmulas de complejidad creciente: G1 solo tiene una curva para la historia, las indicadoras de historia y el tipo; G2 agrega curvas para superficie y antigüedad y las variables de uso, barrio, estacionamiento y pisos; G3 agrega una curva para la EUI de $a-3$ y los predictores restantes (fracción del uso principal, número de usos y número de edificios). Para el bosque, 300 árboles con `mtry` en $\{3, 5, 8, 12\}$ y tamaño mínimo de nodo en $\{5, 20, 50\}$. En total son 35 configuraciones (20 del lasso, 3 del GAM y 12 del bosque), sin superar el máximo de 20 por familia que fija el enunciado, y cada una se evalúa en las tres ventanas (Anexo A.1). Con un núcleo, la búsqueda tomó 117 s para el bosque, 40 s para el GAM y menos de 1 s para el lasso.

5. Resultados

5.1. Desarrollo: validación en 2019–2021

En desarrollo ningún procedimiento superó a la referencia (Tabla 3). El lasso tuvo el menor MAE de los tres y quedó 0,06 kBtu/pie² por encima de la referencia, con un intervalo que incluye el 0 ($[-0{,}19;\ 0{,}35]$). La diferencia cambia

Tabla 3
Comparación en desarrollo: 10 035 filas de validación (2019–2021), las mismas para todos. MAE y RMSE en kBtu/pie². La referencia predice la EUI de $a-2$ (si falta, la mediana del tipo). «Dif.» es el MAE del procedimiento menos el de la referencia, reunido y por ventana; el intervalo remuestrea edificios con predicciones fijas.

Procedimiento	Configuración	MAE	RMSE	Dif.	IC 95 %	Dif. 2019	Dif. 2020	Dif. 2021
Referencia	—	10,44	24,0	—	—	—	—	—
Lasso (elegido)	$\lambda = 0{,}005332$	10,50	24,7	+0,06	[−0,19; 0,35]	+0,95	−0,61	−0,16
GAM	G1	10,52	24,5	+0,08	[−0,10; 0,28]	+0,88	−0,23	−0,44
Bosque	mtry 5, nodo 5	10,52	24,6	+0,08	[−0,14; 0,32]	+0,50	−0,18	−0,07

de signo según la ventana, pues los tres modelos pierden en 2019, y el lasso gana en 2020 y 2021. Además, los tres modelos quedan muy cerca entre sí (MAE entre 10,50 y 10,52), mucho más cerca que la variación entre ventanas, así que el orden entre familias es frágil. El lasso también es el más simple y barato, este conserva en promedio 23 de 49 coeficientes, frente a 16,6 grados de libertad efectivos del GAM y 300 árboles del bosque.

En cuanto a los supuestos, la mediana del residuo en log es prácticamente 0 dentro del entrenamiento (entre 0,003 y 0,012), así que exp() entrega la mediana condicional. Fuera de la muestra la mediana es negativa, es decir, los modelos sobrestiman cuando todo un año baja. Por ejemplo, la mediana del cambio de log(EUI) respecto de $a-2$ fue +0,060 en 2017, el único año de entrenamiento de la primera ventana, y −0,047 en 2019, el año que valida. El error absoluto en log se mantiene casi constante entre quintiles del nivel predicho (mediana entre 0,09 y 0,14), lo que confirma que el error es aproximadamente proporcional al nivel. En el GAM, la prueba de dimensión de base no indica falta de flexibilidad (valor p 0,85) y la concurvidad de la curva de historia es baja (0,30 en el peor caso). Los residuos por ventana están en el Anexo A.6.

5.2. Prueba: evaluación única en 2023–2024

Tabla 4
Comparación en prueba: 7001 filas de 3638 edificios (3496 en 2023 y 3505 en 2024), las mismas para todos. MAE y RMSE en kBtu/pie². «Dif.» es la diferencia de MAE con la referencia de la ficha; el intervalo remuestrea edificios con predicciones fijas. GAM y bosque se informan, pero no se usaron para elegir.

Procedimiento	MAE	RMSE	Dif. MAE	IC 95 %	MAE 2023	MAE 2024
Referencia: EUI de $a-2$	10,69	28,2	—	—	10,44	10,95
Ref. alternativa: última EUI	10,01	24,3	−0,69	—	9,73	10,28
Lasso (elegido)	9,86	26,3	−0,84	[−1,40; −0,23]	9,87	9,84
GAM G1	9,84	23,9	−0,85	[−1,25; −0,48]	9,97	9,71
Bosque	9,50	22,7	−1,19	[−1,73; −0,67]	9,49	9,51

En la prueba, el lasso tuvo un MAE de 9,86 kBtu/pie², 0,84 menos que la referencia de la ficha, con intervalo [−1,40; −0,23] (Tabla 4). La ventaja fue mayor en 2024 (−1,11) que en 2023 (−0,57, con un intervalo que incluye el 0). El GAM y el bosque también superaron a la referencia, y el bosque obtuvo el menor MAE (9,50). Sin embargo, cambiar de procedimiento después de ver la prueba invalidaría la evaluación, por lo que se mantiene el lasso. Su RMSE (26,3) es menor que el de la referencia, pero mayor que el de la referencia alternativa, porque comete algunos errores muy grandes (sección 5.3).

¿Por qué el lasso gana en prueba y no en desarrollo? La Tabla 5 separa las filas según la historia disponible. Cuando existe la EUI de $a-2$, la ventaja del lasso es pequeña (9,08 frente a 9,20). La diferencia está en las 631 filas que solo tienen historia más antigua: ahí la referencia de la ficha usa la mediana del tipo y llega a un MAE de 22,77, mientras el lasso, que usa la última EUI, baja a 15,16. Esas filas explican 0,69 de los 0,84 de ventaja, y en desarrollo eran apenas 75. La referencia alternativa, que también usa la última EUI, logra 15,13 en ese grupo. Frente a ella, el

Tabla 5
MAE en prueba (kBtu/pie²) según la historia disponible. El aporte es la diferencia de MAE del lasso con la referencia en el grupo, ponderada por su fracción de filas; los tres aportes suman −0,839.

Historia disponible	n	Ref.	Ref. alt.	Lasso	GAM	Bosque	Aporte a la dif. del lasso
EUI en $a-2$	6115	9,20	9,20	9,08	9,05	8,64	−0,106
Solo historia anterior a $a-2$	631	22,77	15,13	15,16	15,30	15,46	−0,686
Sin historia	255	16,62	16,62	15,32	15,34	15,46	−0,047

lasso gana solo 0,15 en total, con un intervalo que incluye el 0 y un signo que cambia entre años. Sin historia, el lasso mejora a la mediana del tipo en 1,3 kBtu/pie².

5.3. Análisis de errores

El error cambia más entre años que entre procedimientos (Figura 3A). Todos alcanzan su mayor MAE en 2021, y la ventaja del lasso cambia de signo de un año a otro. La Figura 3B explica la razón, en 2020 y 2021 los cambios de cada edificio respecto de $a-2$ fueron los más dispersos del período, con rangos intercuartiles de 0,23 y 0,21 en log, frente a 0,14–0,16 en los demás años. La pandemia afectó sobre todo a los edificios no residenciales, cuya EUI bajó en mediana un 13 % en 2020, mientras la de los multifamiliares de 5 a 9 pisos no cambió (Anexo A.7). Un choque así hace que el desempeño de un año no garantice el del siguiente.

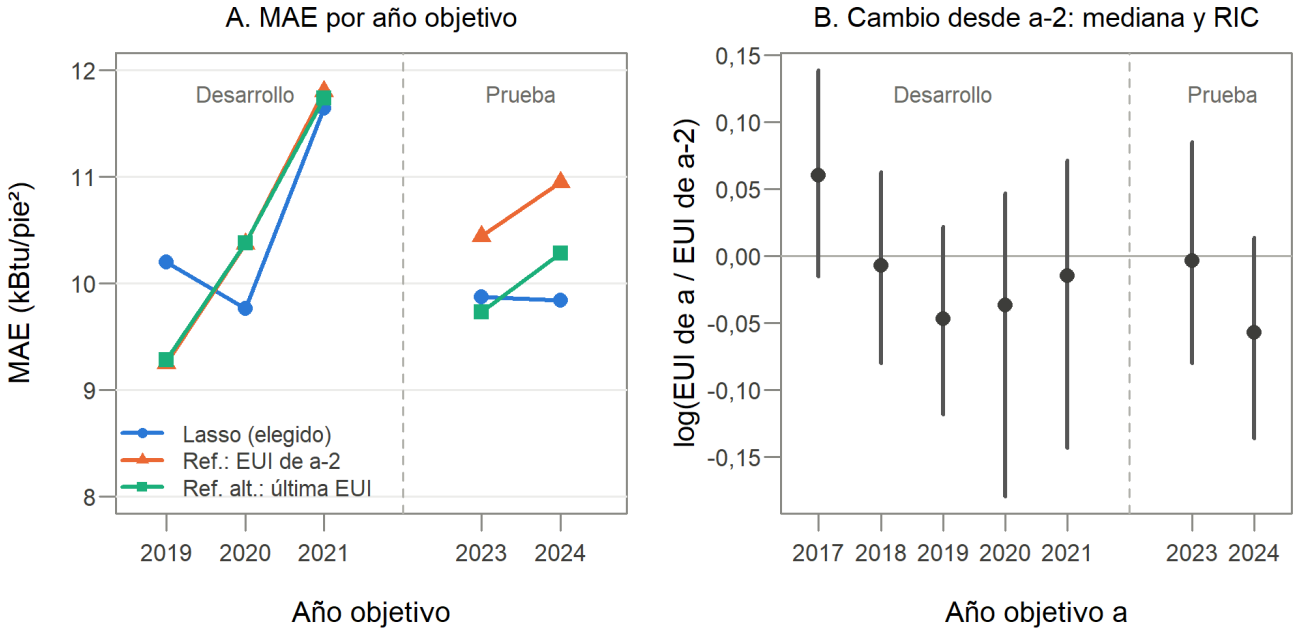


Figura 3
Error por año y choques comunes. A: MAE (kBtu/pie²) del lasso y de las dos referencias en cada año evaluado. B: mediana (punto) y rango intercuartil (barra) del cambio log(EUI de a / EUI de a − 2) en los edificios con ambos valores.

Por subgrupos (Tabla 6), el lasso mejora a la referencia alternativa en multifamiliares y escuelas, pero es peor en hospitales (+2,1), edificios no residenciales (+1,1) y universidades (+6,9, con solo 69 filas). Según el tamaño, es mejor en los tres quintiles menores de superficie y peor en los dos mayores. Por uso principal (Anexo A.8), gana en vivienda multifamiliar, bodegas, escuelas y lugares de culto, empata en oficinas y pierde en hoteles, comercio y usos poco frecuentes.

El lasso no es confiable en los edificios de consumo muy alto. Los puntos negros de la Figura 4 son las 62 filas cuya

Tabla 6

MAE en prueba (kBtu/pie²) del lasso y de la referencia alternativa, por tipo de edificio y por quintil de superficie (pie², cortes del entrenamiento final). Ambos se evalúan en las mismas filas de cada grupo; una diferencia negativa indica que el lasso erra menos.

Grupo	n	Ref. alt.	Lasso	Diferencia (lasso − ref. alt.)
Por tipo de edificio				
Escuela	284	9,23	6,31	−2,92
Multifamiliar, 1 a 4 pisos	2054	7,43	6,03	−1,40
Multifamiliar, 5 a 9 pisos	1572	5,89	5,38	−0,51
Multifamiliar, 10 o más pisos	284	8,09	7,64	−0,45
No residencial	2644	14,27	15,37	+1,10
Hospital	94	16,47	18,61	+2,15
Universidad	69	19,30	26,20	+6,90
Por quintil de superficie				
Q1 (< 26 964)	1293	10,31	10,08	−0,22
Q2 (26 964–38 630)	1384	10,84	9,81	−1,03
Q3 (38 630–60 375)	1377	9,77	9,16	−0,61
Q4 (60 375–125 607)	1432	9,49	10,00	+0,51
Q5 (≥ 125 607)	1515	9,69	10,19	+0,50

última EUI supera 283 kBtu/pie², el percentil 99 del entrenamiento. La mayoría queda sobre la línea discontinua, es decir, la EUI observada es mayor que la predicha: en mediana, el lasso predice 27,4 kBtu/pie² menos de lo observado. En ese grupo su MAE es 113,2, frente a 89,8 de la referencia alternativa, mientras que en el resto de las filas el lasso es mejor (8,93 frente a 9,29).

La subestimación se debe a que, en el lasso final, los coeficientes de la historia suman 0,86 en escala log, y no 1. Por eso la predicción no sigue a la historia en la misma proporción, sino que la acerca al centro de la distribución, si un edificio consumía el doble que otro, el modelo predice que consumirá unas 1,8 veces más (2 elevado a 0,86). En los consumos más altos, ese recorte se nota más. Estos pocos edificios también explican el RMSE: el 1 % de las filas con mayor error concentra el 70 % del error cuadrático del lasso (Anexo A.9).

Si cada edificio pesa lo mismo, el orden se mantiene: el MAE por edificio es 10,08 para el lasso, 10,28 para la referencia alternativa y 10,98 para la de la ficha. En términos relativos, el error típico del lasso equivale a 23 % de la mediana de su tipo.

5.4. Sensibilidades

Tabla 7

Sensibilidades en desarrollo (10 035 filas de validación; MAE en kBtu/pie²). S1 repite la búsqueda sin transformar la respuesta. S2 saca de todos los entrenamientos el 20 % de los edificios y muestra el cambio del MAE en esos edificios y en los demás. La última columna rehace la base sin la regla de errores de registro y evalúa en las mismas filas válidas.

Procedimiento	MAE base (log)	S1: MAE en escala original	S2: cambio, excluidos	S2: cambio, incluidos	Sin regla: MAE, mismas filas
Referencia	10,44	—	+0,01	0,00	12,18
Lasso	10,50	11,23	+0,14	+0,05	10,74
GAM	10,52	11,42	+0,29	+0,06	11,74
Bosque	10,52	11,27	+0,80	+0,09	10,55

S1, escala de la respuesta (decisión de representación). Repetimos toda la búsqueda con la EUI y la historia sin logaritmo, con las mismas ventanas, filas y presupuesto (Tabla 7). Notamos que en los tres procedimientos el MAE

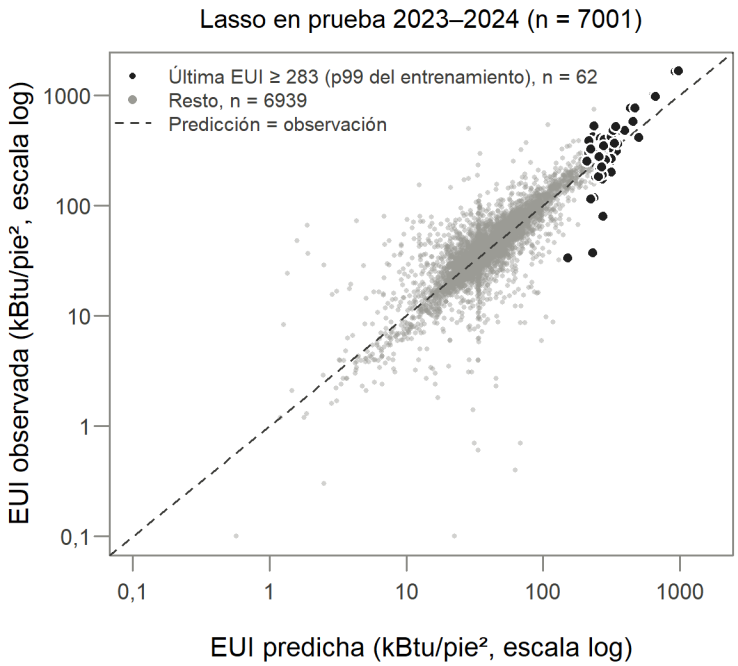


Figura 4
EUI observada frente a predicha por el lasso en la prueba, en escala logarítmica (kBtu/pie²). En negro, las 62 filas cuya última EUI supera el percentil 99 del entrenamiento (283 kBtu/pie²); la línea discontinua marca predicción igual a observación. Los puntos sobre la línea son filas en que el modelo predijo menos de lo observado.

sube entre 0,7 y 0,9 kBtu/pie², y el GAM G3 llega a producir 2265 predicciones negativas. El RMSE del lasso y del GAM baja levemente, lo esperable al estimar la media condicional en vez de la mediana. De todas formas, se pueden determinar las mismas conclusiones, ya que el lasso sigue siendo el de menor MAE, ningún modelo supera a la referencia, y la escala log es la que corresponde a la métrica principal, como anticipaba la descripción de la sección 2.6.

S2, edificios nuevos (decisión de validación). Sacamos de todos los entrenamientos un 20 % de los edificios, elegidos al azar con semilla fija (721 edificios), y comparamos en las mismas filas, en la línea del diagnóstico de sensibilidad de la sesión S17 (EYP3407, 2026). Para esos edificios, el MAE sube 0,14 en el lasso, 0,29 en el GAM y 0,80 en el bosque, y en los demás sube menos de 0,1. El bosque es el que más depende de haber visto al edificio, así que su ventaja en prueba podría no repetirse con edificios nuevos. La conclusión de desarrollo tampoco cambia, ya que el lasso sigue siendo el mejor de los tres y ninguno supera a la referencia. Elegimos esta sensibilidad en vez de quitar el predictor de consumo histórico, como sugiere la ficha, porque la historia es la base de la referencia y de los tres modelos. Además, lo que ocurre sin historia ya se ve en las filas que no la tienen (Tabla 5), donde el MAE en prueba sube a 15,3 kBtu/pie².

Control de la regla de errores de registro. Sin la regla, en las mismas filas válidas, el MAE de la referencia sube de 10,44 a 12,18, porque los registros erróneos pasan a ser historia. Es decir, sin la regla unos pocos registros erróneos distorsionan la comparación.

6. Discusión

6.1. Respuesta a la pregunta

Con información hasta $a-2$, la EUI anual de un edificio conocido se anticipa con un MAE cercano a 10 kBtu/pie², alrededor de un cuarto del nivel típico de su tipo. Casi toda la información útil está en la historia del propio edificio, como sugería la descripción de los datos: cuando existe la EUI de $a-2$, el lasso apenas mejora a la persistencia, y su ventaja frente a la referencia de la ficha viene de usar la última EUI cuando falta la de $a-2$. Los atributos del edificio ayudan sobre todo cuando no hay historia. Los coeficientes del lasso (Anexo A.2) son asociaciones predictivas; con predictores correlacionados, como superficie, pisos y tipo, no deben leerse como efectos causales.

6.2. Utilidad y condiciones de uso

En desarrollo el lasso no superó a la referencia, y en prueba su ganancia frente a una persistencia bien construida (la referencia alternativa) es de 0,15 kBtu/pie², con un intervalo que incluye el 0. Es una ganancia pequeña e incierta, que por sí sola no justifica la mayor complejidad. Como herramienta para el programa, sugerimos:

- **Con historia:** usar la última EUI reportada hasta $a-2$. El lasso rinde casi igual, pero es más complejo y menos confiable en edificios grandes, hospitales, universidades y consumos extremos.
- **Sin historia:** usar el lasso, que mejora a la mediana del tipo en 1,3 kBtu/pie².
- **Consumo previo extremo** ($\geq$ 283 kBtu/pie²): no usar el lasso, que subestima.
- **Cada año:** reajustar con los nuevos reportes y revisar si hubo un choque común, que ningún modelo entrenado con años anteriores puede anticipar.

Estas sugerencias se basan en comparaciones definidas antes de abrir la prueba, pero en solo dos años, así que conviene confirmarlas con años nuevos.

6.3. Límites de generalización

El estudio tiene cuatro límites principales. Primero, la evaluación es retrospectiva: usamos la base descargada en 2026, en la que la ciudad pudo corregir reportes antiguos, y algunos atributos aparecen con su valor actual en todos los años; ambas cosas pueden hacer que los resultados sean algo optimistas. Segundo, las conclusiones valen solo para edificios que reportan en el año objetivo: no sabemos cuánto sería el error en los que no reportaron, y en los edificios sin historia el error es mucho mayor (MAE de 15,3 en prueba). Tercero, la prueba cubre solo dos años, ambos posteriores a la pandemia, y los intervalos no incluyen la variación entre años, que en desarrollo llegó a cambiar el signo de las diferencias. Por último, los umbrales de la regla de errores de registro los fijó el equipo y no provienen de una norma externa, en el control de la sección 5.4 muestra qué ocurre si no se aplica la regla.

6.4. Errores detectados y su corrección

- **Regla de selección con ventanas dependientes.** El plan inicial usaba la regla de un error estándar (EYP3407, 2026, sesión S03), con el error estándar calculado a partir de los tres MAE por ventana. Como las ventanas comparten edificios y datos, y los choques por año inflan esa dispersión, la regla elegía un lasso mucho más penalizado (λ = 0,03284, MAE 10,94). Por eso, antes de abrir la prueba, cambiamos la regla y elegimos simplemente el menor MAE reunido (EYP3407, 2026, sesión S10 y enunciado 4.3). Con este cambio, el lasso elegido pasó a λ = 0,005332.
- **Orden de categorías dependiente del idioma.** Para usar una variable categórica, el lasso la convierte en indicadoras y deja una categoría como base. R elige esa base por orden alfabético, y ese orden cambia según la configuración de idioma del computador (por ejemplo, en cómo ordena tildes y mayúsculas). Como la

penalización del lasso depende de cuál es la base, en otro computador el ajuste podía cambiar levemente. Lo detectamos después de evaluar la prueba y fijamos el orden en `analisis.R`. Al repetir el análisis, todas las tablas y predicciones salieron idénticas, así que los resultados no cambiaron.

- **Fuga, prueba y duplicados.** Ninguna verificación encontró fuga (sección 3.2), la prueba se evaluó una sola vez con decisiones congeladas, la clave edificio–año es única y cada exclusión está documentada.

7. Reproducibilidad y contribuciones

- **Comando:** `Rscript --vanilla analisis.R`, desde la raíz del repositorio y con el paquete de datos descomprimido en `datos/`. Ejecuta la preparación, las particiones, el ajuste, la evaluación, las figuras y este informe.
- **Versión del repositorio:** commit `14a84c6`. Enlace: https://github.com/JuanPabloCuevas/Proyecto-EYP3407-Grupo-4.
- **Entradas:** `caso04_seattle_edificios.zip`, descomprimido en `datos/` con sus tres archivos: `datos.csv`, `diccionario.csv` y `LEEME.txt`.
- **Huella de la entrada:** md5 de `datos.csv`, bc623281c6ad5a50017d5f0d8e2a3b1a.
- **Entorno y tiempo:** R 4.5.3 (R Core Team, 2026) en Windows 11 x64 (build 26200), 12 núcleos; el análisis tomó 6,0 minutos, más la generación de este informe. Paquetes: dplyr 1.2.1, glmnet 5.2, mgcv 1.9-5, ranger 0.18.0, rmarkdown 2.32, knitr 1.52. Semilla 3407 para el bosque, el remuestreo y la muestra de S2; los modelos usan un núcleo.
- **Salidas:** tablas, predicciones y figuras en `resultados/`; las decisiones congeladas antes de la prueba y su registro de cambios, en `CONGELADO.md`; la prueba desde una copia limpia, en `README.md`.
- **Contribuciones:** Maximiliano León coordinó y desarrolló el análisis final (código, validación, modelos, prueba e informe) y preparó el repositorio; Juan Pablo Cuevas desarrolló un análisis paralelo para contrastarlo, hizo la prueba de reproducción y elaboró la presentación; Cristóbal Honorato hizo la auditoría inicial de los datos y propuso la base analítica y las particiones; Michelle Houngbo revisó y validó las sensibilidades, colaboró en la redacción del informe y en la presentación. Detalle en `README.md`.
- **Declaración de uso de IA:** Maximiliano León, Juan Pablo Cuevas y Cristóbal Honorato usaron Claude (Anthropic), y Michelle Houngbo y Michelle Houngbo ChatGPT (OpenAI), como apoyo en programación, depuración y redacción. Las cifras del informe se verifican contra los resultados al compilar, y el análisis se reprodujo desde una copia limpia y en otro computador. Herramienta, fechas, propósito y partes afectadas de cada integrante, en `README.md`.

Referencias

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.

City of Seattle, Office of Sustainability and Environment (2026). *Building Energy Benchmarking Data, 2015-Present* [conjunto de datos `teqw-tu6e`, dominio público]. Portal de datos abiertos de Seattle, https://data.seattle.gov. Copia con los registros 2015–2024 preparada para el curso el 12 de octubre de 2026.

Davison, A. C. y Hinkley, D. V. (1997). *Bootstrap Methods and their Application*. Cambridge University Press.

EYP3407 (2026). *Proyecto aplicado: enunciado, ficha del caso 04 y rúbrica*; sesiones S02 (*Evaluación de modelos*), S03 (*Remuestreo y validación*), S10 (*Selección de variables*), S11 (*Regularización I*), S12 (*Regularización II: alta dimensión*), S14 (*Regresión no lineal II*), S15 (*Modelos aditivos*), S16 (*Árboles*), S17 (*Poda y validación*) y S22 (*Bagging y bosques aleatorios*). Pontificia Universidad Católica de Chile.

Friedman, J., Hastie, T. y Tibshirani, R. (2010). Regularization paths for generalized linear models via coordinate descent. *Journal of Statistical Software*, 33(1), 1–22.

Hyndman, R. J. y Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3.ª ed.). OTexts.

James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in R* (2.ª ed.). Springer.

R Core Team (2026). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Viena.

Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B*, 58(1), 267–288.

Wood, S. N. (2011). Fast stable restricted maximum likelihood and marginal likelihood estimation of semiparametric generalized linear models. *Journal of the Royal Statistical Society: Series B*, 73(1), 3–36.

Wood, S. N. (2017). *Generalized Additive Models: An Introduction with R* (2.ª ed.). Chapman and Hall/CRC.

Wright, M. N. y Ziegler, A. (2017). ranger: A fast implementation of random forests for high dimensional data in C++ and R. *Journal of Statistical Software*, 77(1), 1–17.

A. Anexo técnico

A.1. Búsqueda completa en desarrollo

Tabla 8

Las 35 configuraciones evaluadas en las tres ventanas (10 035 filas). MAE y RMSE reunidos en kBtu/pie². Lasso en orden de penalización decreciente; GAM de G1 a G3; bosque ordenado por MAE.

Familia	Configuración	MAE	RMSE	MAE 2019	MAE 2020	MAE 2021
Lasso	λ = 0,6019	25,61	55,7	26,78	23,40	26,77
Lasso	λ = 0,4184	20,72	49,5	21,69	18,56	22,05
Lasso	λ = 0,2909	17,22	43,5	17,95	15,27	18,58
Lasso	λ = 0,2022	14,77	38,1	15,26	13,04	16,15
Lasso	λ = 0,1406	13,14	33,8	13,38	11,66	14,49
Lasso	λ = 0,09774	12,14	30,7	12,17	10,92	13,43
Lasso	λ = 0,06795	11,52	28,5	11,41	10,51	12,76
Lasso	λ = 0,04724	11,15	27,1	10,92	10,30	12,34
Lasso	λ = 0,03284	10,94	26,1	10,64	10,20	12,07
Lasso	λ = 0,02283	10,78	25,6	10,45	10,07	11,92
Lasso	λ = 0,01587	10,65	25,2	10,31	9,92	11,81
Lasso	λ = 0,01103	10,56	24,9	10,24	9,83	11,70
Lasso	λ = 0,00767	10,51	24,8	10,22	9,77	11,64
Lasso	λ = 0,005332 (elegida)	10,50	24,7	10,20	9,76	11,64
Lasso	λ = 0,003707	10,52	24,7	10,20	9,78	11,67
Lasso	λ = 0,002577	10,54	24,7	10,21	9,80	11,69
Lasso	λ = 0,001791	10,55	24,7	10,25	9,81	11,71
Lasso	λ = 0,001245	10,57	24,8	10,28	9,81	11,73
Lasso	λ = 0,0008658	10,59	24,8	10,30	9,83	11,75
Lasso	λ = 0,0006019	10,61	24,8	10,32	9,85	11,75
GAM	G1 (elegida)	10,52	24,5	10,13	10,14	11,35
GAM	G2	10,79	24,9	10,51	10,33	11,59
GAM	G3	10,54	24,5	10,21	9,97	11,53
Bosque	mtry 5, nodo 5 (elegida)	10,52	24,6	9,75	10,19	11,73
Bosque	mtry 8, nodo 5	10,55	24,2	9,80	10,21	11,74
Bosque	mtry 8, nodo 20	10,58	25,5	9,85	10,21	11,78
Bosque	mtry 3, nodo 5	10,60	25,9	9,85	10,20	11,84
Bosque	mtry 5, nodo 20	10,62	26,6	9,90	10,25	11,82
Bosque	mtry 8, nodo 50	10,64	27,1	10,02	10,19	11,81
Bosque	mtry 12, nodo 50	10,68	26,5	10,05	10,23	11,86
Bosque	mtry 12, nodo 20	10,69	25,5	9,92	10,31	11,92
Bosque	mtry 12, nodo 5	10,69	24,3	9,96	10,31	11,90
Bosque	mtry 5, nodo 50	10,73	28,7	10,09	10,37	11,81
Bosque	mtry 3, nodo 20	10,82	28,8	10,20	10,44	11,90
Bosque	mtry 3, nodo 50	11,17	31,5	10,60	10,76	12,23

A.2. Coeficientes del lasso final

Tabla 9

Coeficientes distintos de 0 del lasso ajustado con los objetivos 2017–2021 (λ = 0,005332), en escala de log(EUI) y en las unidades originales de cada predictor (glmnet estandariza los predictores para penalizar, pero entrega los coeficientes en sus unidades). Cada indicadora de categoría se compara con la categoría base de su variable. Son asociaciones predictivas, no efectos causales.

Variable	Coeficiente	Variable	Coeficiente
Constante	0,462	Uso: Office	−0,0003
log(última EUI válida hasta $a-2$)	0,674	Uso: Other	0,012
log(EUI de $a-3$)	0,187	Uso: Otro	0,057
Falta la EUI de $a-3$	0,079	Uso: Self-Storage Facility	−0,100
log(superficie)	0,001	Uso: Senior Living Community	0,012
Fracción de estacionamiento	0,018	Uso: Sin dato	−0,142
log(número de edificios)	0,005	Uso: Supermarket/Grocery Store	0,162
Tipo: University	0,071	Uso: Vehicle Repair Services	0,020
Uso: Distribution Center	−0,015	Barrio: EAST	0,011
Uso: Hospital (General Medical & Surgical)	0,224	Barrio: GREATER DUWAMISH	−0,001
Uso: Hotel	−0,004	Barrio: LAKE UNION	0,017
Uso: K-12 School	0,008	Barrio: MAGNOLIA / QUEEN ANNE	−0,0004
Uso: Laboratory	0,209	Barrio: NORTH	−0,018
Uso: Medical Office	0,086	Barrio: NORTHEAST	0,005
Uso: Non-Refrigerated Warehouse	−0,015		

A.3. Datos por año y descripción de la respuesta

Tabla 10

Registros por año, respuestas faltantes, altas y bajas de edificios respecto del año anterior (2015–2022, sin mirar la prueba) y filas objetivo válidas según la historia disponible (2017–2021 y 2023–2024).

Año	Filas	Sin respuesta	Altas	Bajas	Objetivo: EUI en $a-2$	Solo historia anterior	Sin historia
2015	3175	33	—	—	—	—	—
2016	3253	45	84	6	—	—	—
2017	3310	37	61	4	3109	0	164
2018	3381	39	84	13	3166	12	164
2019	3456	46	89	14	3214	20	175
2020	3530	57	93	19	3266	25	178
2021	3578	419	56	8	3000	30	127
2022	3617	345	50	11	—	—	—
2023	—	—	—	—	3012	361	123
2024	—	—	—	—	3103	270	132

Tabla 11

Distribución de la respuesta en las 16 650 filas de desarrollo.

Escala	Mín.	p1	p25	Mediana	p75	p99	Máx.	Media
EUI (kBtu/pie²)	0,10	5,80	27,60	37,20	57,60	283,46	1538,10	52,46
log(EUI)	−2,30	1,76	3,32	3,62	4,05	5,65	7,34	3,70

Tabla 12

Persistencia: correlación entre la EUI del año objetivo y la de $a-2$, y mediana del cambio log(EUI de a / EUI de $a-2$), en los objetivos de desarrollo con EUI válida en ambos años.

Año objetivo	Pares	Spearman	Pearson en log	Mediana del cambio en log
2017	3109	0,914	0,905	+0,060
2018	3166	0,903	0,903	−0,007
2019	3214	0,891	0,890	−0,047
2020	3266	0,869	0,865	−0,037
2021	3000	0,853	0,829	−0,015

Tabla 13

Cambio respecto de $a-2$ según el nivel de $a-2$ (deciles, 15 755 pares). El cambio absoluto crece con el nivel; el cambio en log, no (Spearman entre nivel y cambio absoluto: 0,47 en kBtu/pie² y 0,07 en log).

Decil	EUI mediana en $a-2$	Mediana de |cambio| (kBtu/pie²)	Mediana de |cambio| en log
1	18,4	1,9	0,121
2	24,5	1,7	0,070
3	28,0	1,8	0,064
4	31,5	2,1	0,068
5	35,8	2,9	0,081
6	41,5	3,9	0,092
7	49,1	5,1	0,103
8	60,3	6,8	0,113
9	78,0	8,6	0,112
10	141,1	16,4	0,105

Tabla 14

Fracción de la variación de la EUI de 2015–2022 que explica la media de cada edificio (suma de cuadrados entre edificios sobre la total), por tipo de edificio. Excluye los errores de registro.

Tipo	Edificios	Filas	Entre edificios, log(EUI)	Entre edificios, EUI
Hospital	57	412	91,6 %	90,7 %
Multifamiliar, 10 o más pisos	136	955	70,1 %	79,0 %
Multifamiliar, 1 a 4 pisos	1086	8092	78,8 %	69,8 %
Multifamiliar, 5 a 9 pisos	771	5153	78,4 %	79,3 %
No residencial	1447	10 403	87,0 %	89,5 %
Escuela	147	1036	75,0 %	75,1 %
Universidad	35	219	89,0 %	98,8 %
Todos	3679	26 270	86,5 %	90,4 %

A.4. Auditoría de columnas

Tabla 15
Columnas no clave en 2015–2022: número de edificios en que el valor cambia entre años (0 indica un valor actual copiado a todos los años) y porcentaje de filas faltantes. Hay 3692 edificios en esos años.

Columna	Cambios	Faltante	Columna	Cambios	Faltante
buildingname	0	0,0 %	siteeui_kbtu_sf	3627	3,7 %
buildingtype	0	0,0 %	siteenergyuse_kbtu	3627	3,7 %
taxparcelidentificationnumber	0	0,0 %	siteenergyusewn_kbtu	3624	4,8 %
address	0	0,0 %	sourceeuiwn_kbtu_sf	3623	4,8 %
city	0	0,0 %	sourceeui_kbtu_sf	3627	3,7 %
state	0	0,0 %	epapropertytype	364	0,0 %
zipcode	0	0,0 %	largestpropertyusetype	331	0,0 %
latitude	0	0,0 %	largestpropertyusetypegfa	1613	0,0 %
longitude	0	0,0 %	secondlargestpropertyusetype	513	40,4 %
neighborhood	0	0,0 %	secondlargestpropertyuse	879	45,5 %
councildistrictcode	0	0,0 %	thirdlargestpropertyusetype	384	75,4 %
yearbuilt	0	0,0 %	thirdlargestpropertyusetypegfa	433	78,2 %
numberoffloors	0	0,0 %	electricity_kwh	3627	2,9 %
numberofbuildings	0	0,0 %	steamuse_kbtu	136	96,5 %
propertygfatotal	0	0,0 %	naturalgas_therms	2484	39,1 %
propertygfabuildings	0	0,0 %	compliancestatus	1236	0,0 %
propertygfaparking	0	0,0 %	complianceissue	1230	1,7 %
selfreportgfatotal	0	0,0 %	electricity_kbtu	3627	2,9 %
selfreportgfabuildings	0	0,0 %	naturalgas_kbtu	2484	39,1 %
selfreportparking	0	0,0 %	totalghgemissions	3628	2,6 %
energystarscore	2997	26,9 %	ghgemissionsintensity	3541	4,6 %
siteeuiwn_kbtu_sf	3623	4,8 %	demolished	0	0,0 %

A.5. Errores de registro y saltos grandes

Tabla 16
Registros de 2015–2022 marcados por la regla (EUI > 10 veces la mediana previa del edificio y > 1000 kBtu/pie²). Otros 18 saltos de más de 10 veces no se marcan porque su nivel es posible.

Edificio	Año	Tipo	EUI	Mediana previa	Veces
50239	2021	Multifamily HR (10+)	42 480,2	23,5	1808
755	2019	NonResidential	17 488,5	71,8	244
755	2020	NonResidential	17 549,6	72,9	241
25042	2022	NonResidential	6389,5	42,8	149
49967	2020	University	6702,9	116,9	57
23689	2021	NonResidential	1952,2	40,7	48
503	2020	NonResidential	3742,4	111,7	34
23120	2022	NonResidential	2544,8	110,5	23
27162	2020	NonResidential	4462,8	286,1	16

A.6. Supuestos y estabilidad

Tabla 17

Residuo en log (log de la EUI observada menos la predicción en log) dentro del entrenamiento de cada ventana (bosque: fuera de bolsa) y en su año de validación, y número de coeficientes del lasso distintos de 0.

Modelo	Ventana	Mediana en entrenamiento	Mediana fuera de muestra	Media fuera de muestra	Coef. lasso no nulos
Lasso	2019	0,006	−0,099	−0,097	21
Lasso	2020	0,007	−0,044	−0,081	24
Lasso	2021	0,003	−0,009	−0,046	25
GAM	2019	0,008	−0,095	−0,097	—
GAM	2020	0,009	−0,058	−0,098	—
GAM	2021	0,008	−0,017	−0,062	—
Bosque	2019	0,009	−0,058	−0,067	—
Bosque	2020	0,012	−0,047	−0,085	—
Bosque	2021	0,010	−0,007	−0,053	—

A.7. Cambio respecto de $a-2$ por tipo de edificio

Tabla 18

Mediana del cambio log(EUI de a / EUI de $a-2$) por tipo de edificio y año objetivo, en los edificios con ambos valores.

Tipo	2017	2018	2019	2020	2021	2023	2024
Hospital	0,026	0,001	−0,056	−0,024	−0,002	−0,016	−0,046
Multifamiliar, 10 o más pisos	0,076	−0,006	−0,053	−0,015	−0,008	−0,022	−0,067
Multifamiliar, 1 a 4 pisos	0,063	−0,004	−0,044	0,008	0,015	−0,009	−0,060
Multifamiliar, 5 a 9 pisos	0,060	0,000	−0,037	0,000	0,000	0,007	−0,040
No residencial	0,049	−0,010	−0,054	−0,138	−0,096	0,010	−0,061
Escuela	0,100	−0,062	−0,059	−0,079	0,186	−0,104	−0,173
Universidad	0,084	0,027	−0,037	−0,062	−0,017	0,042	−0,051

A.8. Error por uso principal en prueba

Tabla 19

MAE en prueba (kBtu/pie²) por uso principal del último registro $\leq a-2$. Conservan su nombre los usos con al menos 300 filas en el entrenamiento final, una regla que no mira la prueba; «Otros usos» reúne los demás. Mismas filas para todos los procedimientos en cada grupo.

Grupo	n	Ref.	Ref. alt.	Lasso	GAM	Bosque	Lasso − ref. alt.
Vivienda multifamiliar	3672	6,75	6,61	5,60	6,05	5,41	−1,01
Oficinas	963	9,26	9,15	9,26	8,78	9,29	+0,11
Bodega no refrigerada	297	11,88	11,16	10,12	10,31	10,51	−1,04
Escuela (K-12)	279	10,56	10,64	7,35	8,99	7,35	−3,28
Hotel	151	14,19	13,56	17,03	16,36	18,47	+3,47
Comercio minorista	143	12,98	12,49	13,57	13,23	14,08	+1,08
Lugar de culto	112	8,98	7,88	6,48	6,84	6,38	−1,41
«Other» de la fuente	96	18,24	16,74	18,20	16,71	17,23	+1,46
Otros usos	1056	22,75	19,35	22,66	21,19	20,57	+3,31
Sin registro de uso $\leq a-2$	232	16,94	16,94	15,29	15,32	15,72	−1,66

A.9. Mayores errores del lasso en prueba

Tabla 20

Las diez filas de prueba con mayor error absoluto del lasso (EUI en kBtu/pie²).

Edificio	Año	Uso previo	Última EUI	Observada	Lasso	Referencia
49780	2023	Data Center	1538,1	1639,7	927,3	1538,1
49780	2024	Data Center	1632,7	1656,5	979,6	1632,7
22479	2024	Supermarket/Grocery Store	282,8	740,9	236,5	282,8
24202	2024	Distribution Center	29,6	494,1	28,5	29,6
49967	2024	College/University	119,5	536,1	108,0	119,5
365	2023	Data Center	909,9	989,2	641,3	909,9
753	2023	Data Center	630,8	761,4	434,1	49,8
365	2024	Data Center	956,7	969,8	663,2	956,7
95	2024	Hotel	87,0	367,5	75,1	49,8
753	2024	Data Center	630,8	756,4	469,8	49,8