EYP3407 - Tópicos Aplicados en Estadística

INTENSIDAD ENERGÉTICA ANUAL DE EDIFICIOS DE SEATTLE

¿Cuánto se puede anticipar con información hasta dos años antes?

Integrantes: Juan Pablo Cuevas, Cristóbal Honorato, Michelle Houngbo y Maximiliano León

INTRODUCCIÓN

La intensidad energética en un edificio (EUI) expresa la cantidad de energía que consume un inmueble en relación con su tamaño. Anticipar la EUI a comienzos del año serviría para la toma de decisiones como planificación para la gestión de recursos o decidir a qué edificios hacer seguimiento.

A partir de esto se define el problema de investigación:

¿Qué tan bien se puede anticipar la intensidad energética anual de edificios conocidos utilizando atributos e historial previamente reportado?

Los datos son publicados por la Office of Sustainability and Environment de Seattle en el portal de datos abiertos de la ciudad como Building Energy Benchmarking Data, 2015-Present. Se consideró la copia preparada para el curso el 12 de octubre de 2026 que incluye 34 699 registros (unidad edificio-año) de 3823 edificios y 46 columnas, reportados entre 2015 y 2024.

DATOS Y MUESTRA

La **población** corresponde a los edificios-año con un reporte válido de EUI en el año objetivo. La variable respuesta es *siteeui_kbtu_sf*, la energía consumida en el sitio durante el año dividida por la superficie bruta, en kBtu/pie^2.

Se realiza una partición temporal para evitar fugas de información. Los años 2015, 2016 y 2022 solo aportan historia.

Error de registro: EUI más de 10 veces la mediana previa del edificio y sobre 1000 kBtu/pie². Son 14 registros, que no se usan como objetivo ni como historia

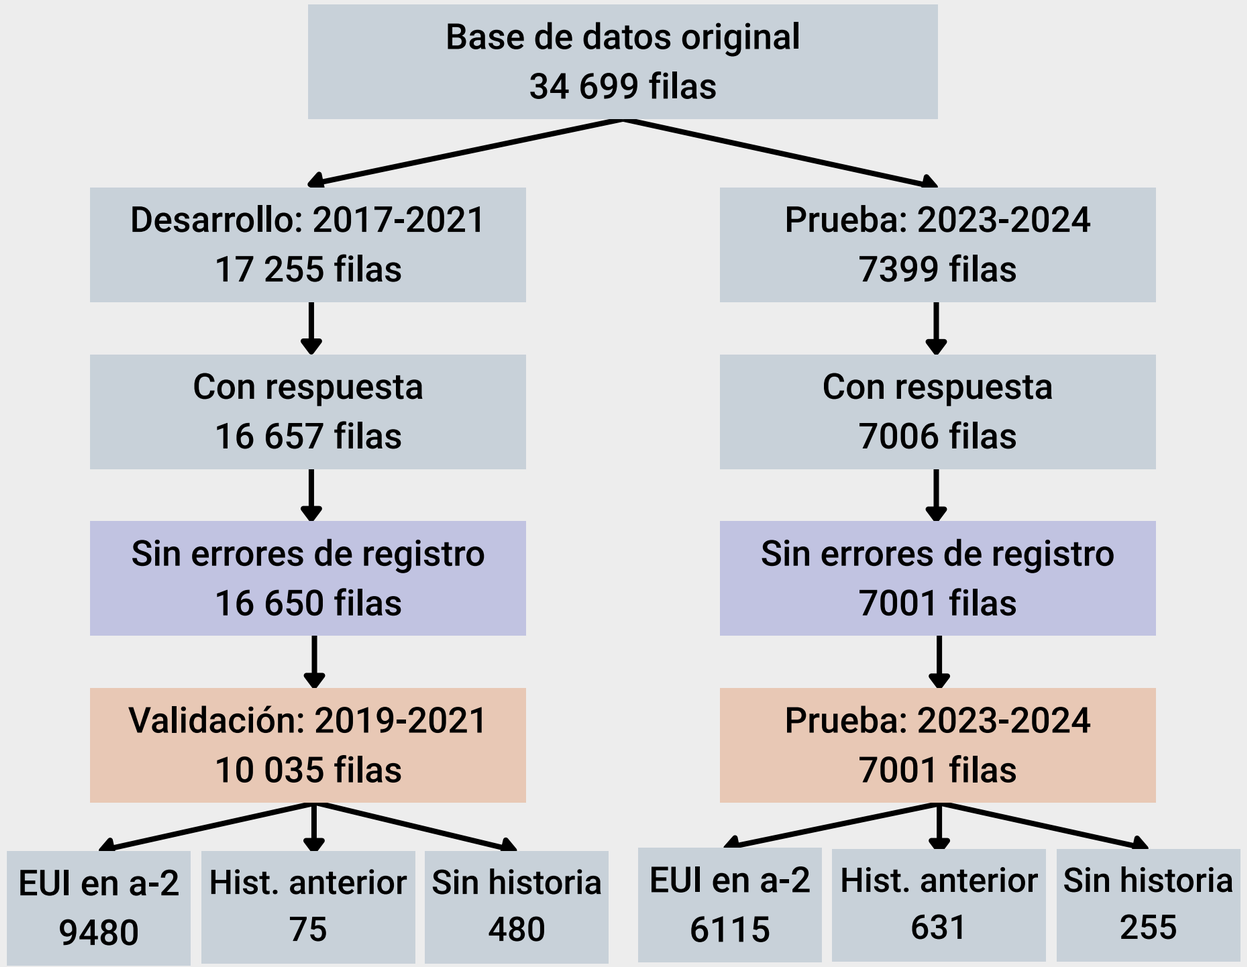


Figura 1: Diagrama de construcción de la muestra.

DISEÑO DE VALIDACIÓN

Se consideran tres ventanas crecientes con información desde 2015, se entrenan con respuestas hasta a - 2 y se validan en 2019, 2020 y 2021.

El año **a - 1** no se utiliza ya que en enero del año **a** todavía está incompleto.

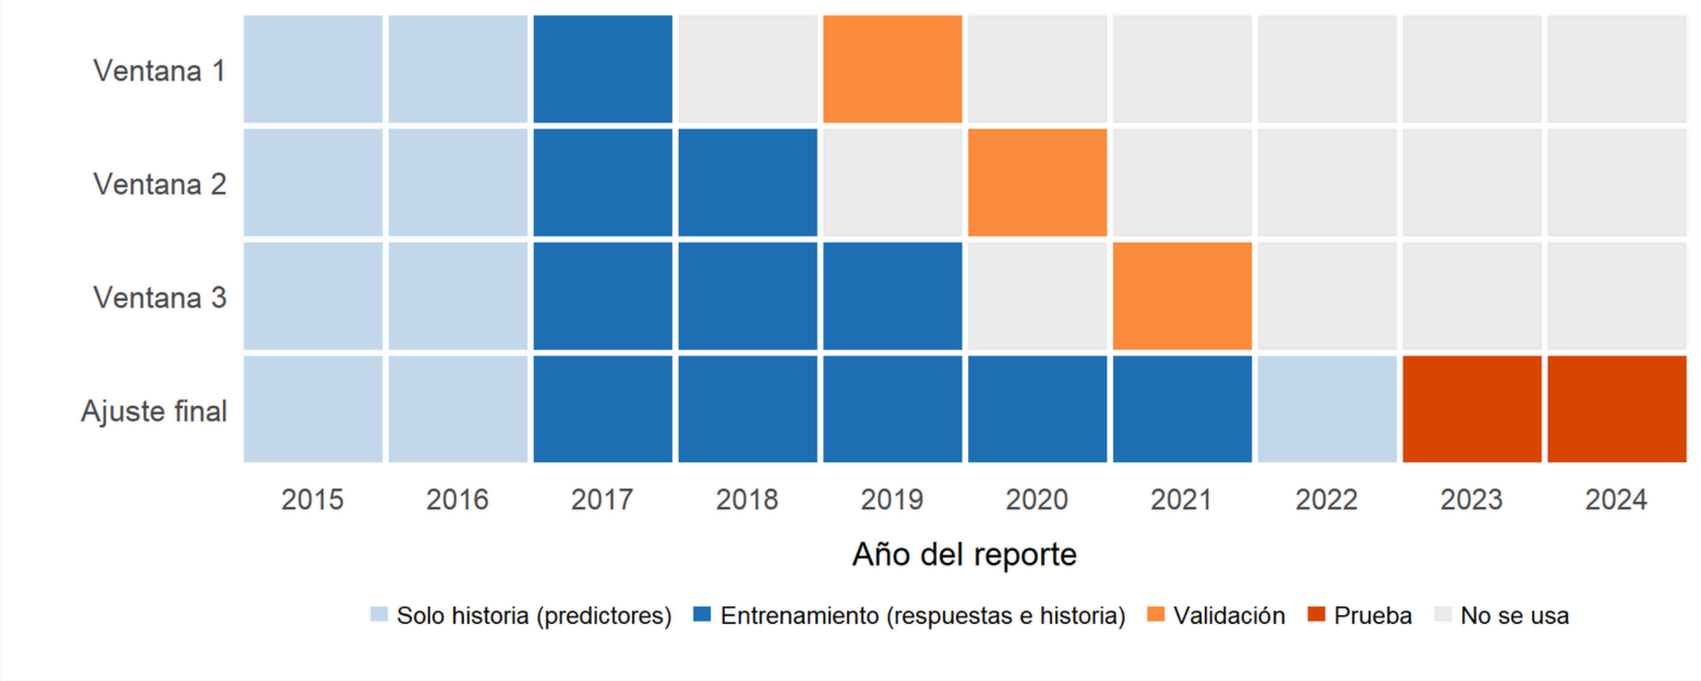


Figura 2: Diseño temporal de la evaluación.

La prueba se realizó una sola vez, con las decisiones congeladas previamente

INFORMACIÓN ADMISIBLE

Variables usadas	Variables excluidas
Características del edificio (barrio, superficie, etc.)	Medidas del año objetivo (emisiones, consumo, etc.)
Usos del edificio (tipo de uso y superficie)	Campos que se conocen después (distrito, demolición, etc.)
Historia de la respuesta (EUI de años $\leqslant a - 2$)	Identificador o repetición

Tabla 1: Variables usadas y excluidas.

Prueba de fuga: se repiten predicciones modificando al azar la EUI y los usos de los años posteriores a cada corte. Se obtiene que las predicciones no cambian, por lo que el código no utiliza información futura.

Solo se tiene acceso a la base descargada actualmente, no a la que existía cada año, por lo que la evaluación puede resultar optimista.

METODOLOGÍA

Referencia

Se predice con la EUI de **a−2** o, si ese año falta, con la mediana del tipo en el entrenamiento.

Para los casos en que falta **a−2** pero hay años anteriores, se define, antes de abrir la prueba, una referencia alternativa que usa la última EUI válida hasta **a−2**.

Modelos de flexibilidad creciente

- **M1, lasso**: persistencia en escala logarítmica, más ajustes aditivos y selección de variables por la penalización
- **M2, GAM**: agrega curvas suaves para la historia, el tamaño y la antigüedad
- **M3, bosque aleatorio**: capta interacciones sin especificarlas

Se modela log(EUI) por la asimetría de la variable y porque su error crece con el nivel.

RESULTADOS

Procedimiento	Configuración	MAE	RMSE	Dif.	IC 95%	Dif. 2019	Dif. 2020	Dif. 2021
Referencia	—	10.44	24.0	—	—	—	—	—
Lasso	λ = 0.005332	10.50	24.7	+0.06	[-0.19, 0.35]	+0.95	-0.61	-0.16
GAM	G1	10.52	24.5	+0.08	[-0.10, 0.28]	+0.88	-0.23	-0.44
Bosque Aleatorio	mtry 5 nodo 5	10.52	24.6	+0.08	[-0.14, 0.32]	+0.50	-0.18	-0.07

Tabla 2: Comparación resultados de modelos en desarrollo.

Ningún modelo supera a la referencia: los tres IC incluyen el 0. Se selecciona el lasso por el criterio congelado de menor MAE entre los tres; además es el más simple.

Cálculo del IC 95%: 2000 réplicas bootstrap por edificio, con predicciones fijas.

RESULTADOS

Procedimiento	MAE	RMSE	Dif. MAE	IC 95%
Referencia	10.69	28.2	—	—
Referencia alternativa	10.01	24.3	-0.69	—
Lasso	9.86	26.3	-0.84	[-1.40, -0.23]
GAM	9.84	23.9	-0.85	[-1.25, -0.48]
Bosque aleatorio	9.50	22.7	-1.19	[-1.73, -0.67]

Tabla 3: Comparación de resultados en prueba.

En prueba **lasso** mejora el MAE de la referencia en 0.84, pero 0.69 vienen de 631 filas sin EUI en a − 2. Frente a la referencia alternativa la diferencia es de −0.15, con IC 95 % [−0.63, 0.38]: no hay mejora clara.

ANÁLISIS DE ERRORES

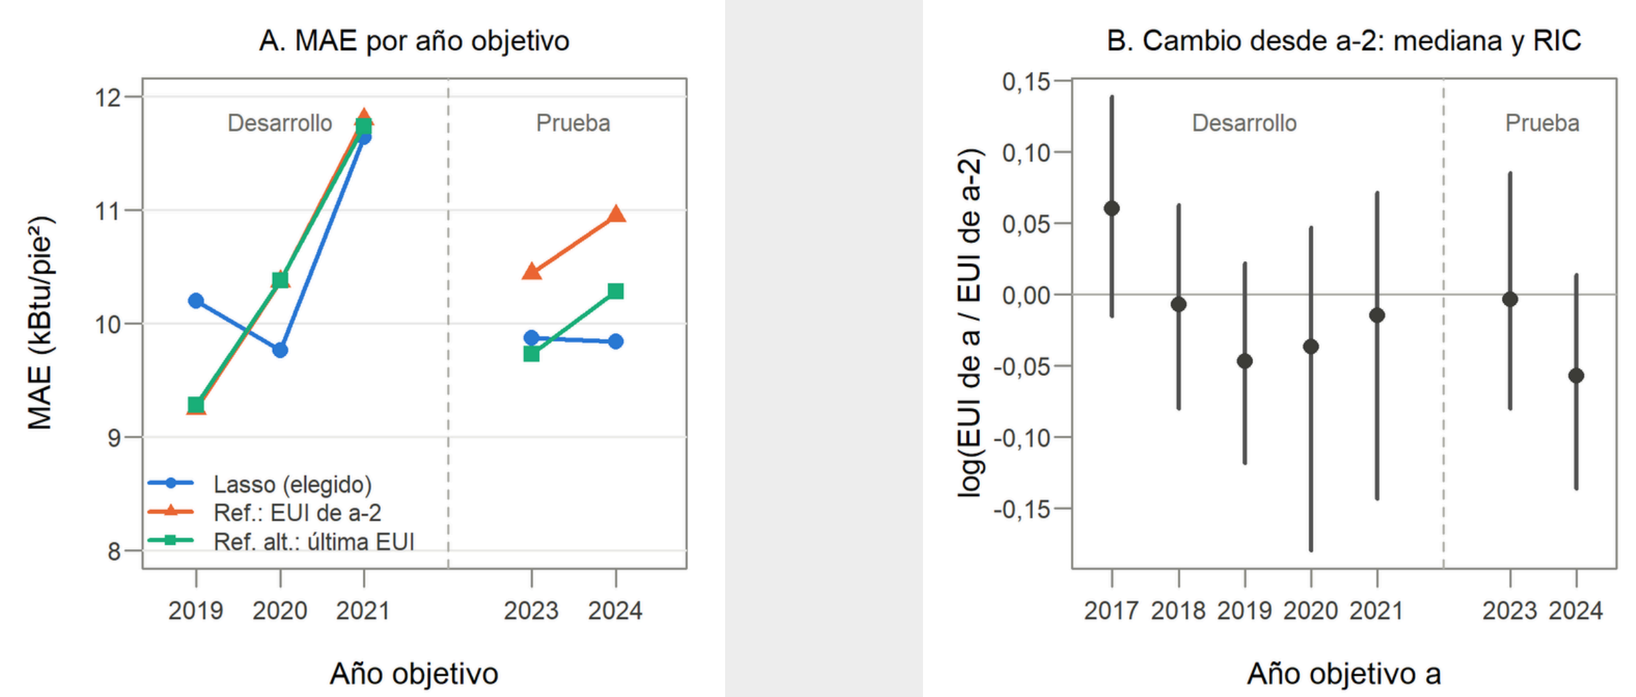


Figura 3: A: MAE por año objetivo en M1 y referencias, en desarrollo y prueba. B: mediana y rango intercuartil del cambio log(EUI de a / EUI de a − 2) en edificios disponibles.

Efecto de la pandemia: en 2020 y 2021 los cambios respecto a **a - 2** fueron más dispersos.

Extremos (última EUI $\geqslant$ 283 kBtu/pie²)**:** lasso tiene MAE 113.2, frente a 89.8 de la ref. alternativa.

Subgrupos (frente a la ref. alternativa)**:** lasso gana en multifamiliares y escuelas; pierde en hospitales (+2.1), no residenciales (+1.1), universidades (+6.9) y edificios grandes.

SENSIBILIDAD

Procedimiento	MAE base (log)	S1: MAE en escala original	S2: cambio, excluidos	S2: cambio, incluidos	Sin regla: MAE, mismas filas
Referencia	10.44	—	+0.01	0.00	12.18
Lasso	10.50	11.23	+0.14	+0.05	10.74
GAM	10.52	11.42	+0.29	+0.06	11.74
Bosque aleatorio	10.52	11.27	+0.80	+0.09	10.55

Tabla 4: Análisis de sensibilidad.

S1, decisión de representación: se prefiere la escala logarítmica sobre la original.
S2, decisión de validación: al excluir el 20 % de los edificios de los entrenamientos el bosque muestra mayor dependencia de haber visto previamente cada edificio.
Sin regla de errores el MAE de referencia aumenta, registros erróneos distorsionan la comparación.

CONCLUSIONES

Con información hasta a − 2, la EUI anual de un edificio conocido se anticipa con un MAE cercano a 10 kBtu/pie² (en prueba: 9.86 con el lasso elegido y 10.69 con la referencia), alrededor de un cuarto del nivel típico de su tipo. Casi toda la información útil está en la historia del propio edificio.

Recomendación de uso:

- **Con historia:** usar última EUI reportada. En toda la prueba, el lasso no la supera con claridad (−0.15, IC 95 % [−0.63, 0.38])
- **Sin historia:** usar el lasso (MAE 15.3 frente a 16.6 de la mediana del tipo)
- **Consumo previo ⩾ 283 kBtu/pie²:** no usar el lasso, porque subestima (MAE 113.2 frente a 89.8)
- Reajustar cada año con los nuevos reportes

Principales limitaciones:

- Evaluación retrospectiva con la base descargada en 2026: puede ser optimista
- Vale solo para edificios que reportan en el año objetivo
- Prueba de dos años, ambos posteriores a la pandemia
- Umbrales de la regla de errores de registro definidos por el equipo

El análisis fue realizado mediante un código reproducible: un comando, R*script --vanilla analisis.R*, en 6 minutos. Reproducido en otro computador y con prueba de fuga superada

ANEXO

BIBLIOGRAFÍA

- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- City of Seattle, Office of Sustainability and Environment (2026). *Building Energy Benchmarking Data, 2015-Present* [conjunto de datos teqw-tu6e, dominio público]. Portal de datos abiertos de Seattle, https://data.seattle.gov. Copia con los registros 2015–2024 preparada para el curso el 12 de octubre de 2026.
- Davison, A. C. y Hinkley, D. V. (1997). *Bootstrap Methods and their Application.* Cambridge University Press.
- EYP3407 (2026). *Proyecto aplicado: enunciado, ficha del caso 04 y rúbrica; sesiones S02 (Evaluación de modelos), S03 (Remuestreo y validación), S10 (Selección de variables), S11 (Regularización I), S12 (Regularización II: alta dimensión), S14 (Regresión no lineal II), S15 (Modelos aditivos), S16 (Árboles), S17 (Poda y validación) y S22 (Bagging y bosques aleatorios).* Pontificia Universidad Católica de Chile.
- Friedman, J., Hastie, T. y Tibshirani, R. (2010). Regularization paths for generalized linear models via coordinate descent. *Journal of Statistical Software*, 33(1), 1–22.
- Hyndman, R. J. y Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3.ª ed.). OTexts.
- James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in R* (2.ª ed.). Springer.
- R Core Team (2026). *R: A Language and Environment for Statistical Computing. R Foundation for Statistical Computing*, Viena.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B,* 58(1), 267–288.
- Wood, S. N. (2011). Fast stable restricted maximum likelihood and marginal likelihood estimation of semiparametric generalized linear models. *Journal of the Royal Statistical Society: Series B,* 73(1), 3–36.
- Wood, S. N. (2017). *Generalized Additive Models: An Introduction with R* (2.ª ed.). Chapman and Hall/CRC.
- Wright, M. N. y Ziegler, A. (2017). ranger: A fast implementation of random forests for high dimensional data in C++ and R. *Journal of Statistical Software*, 77(1), 1–17.

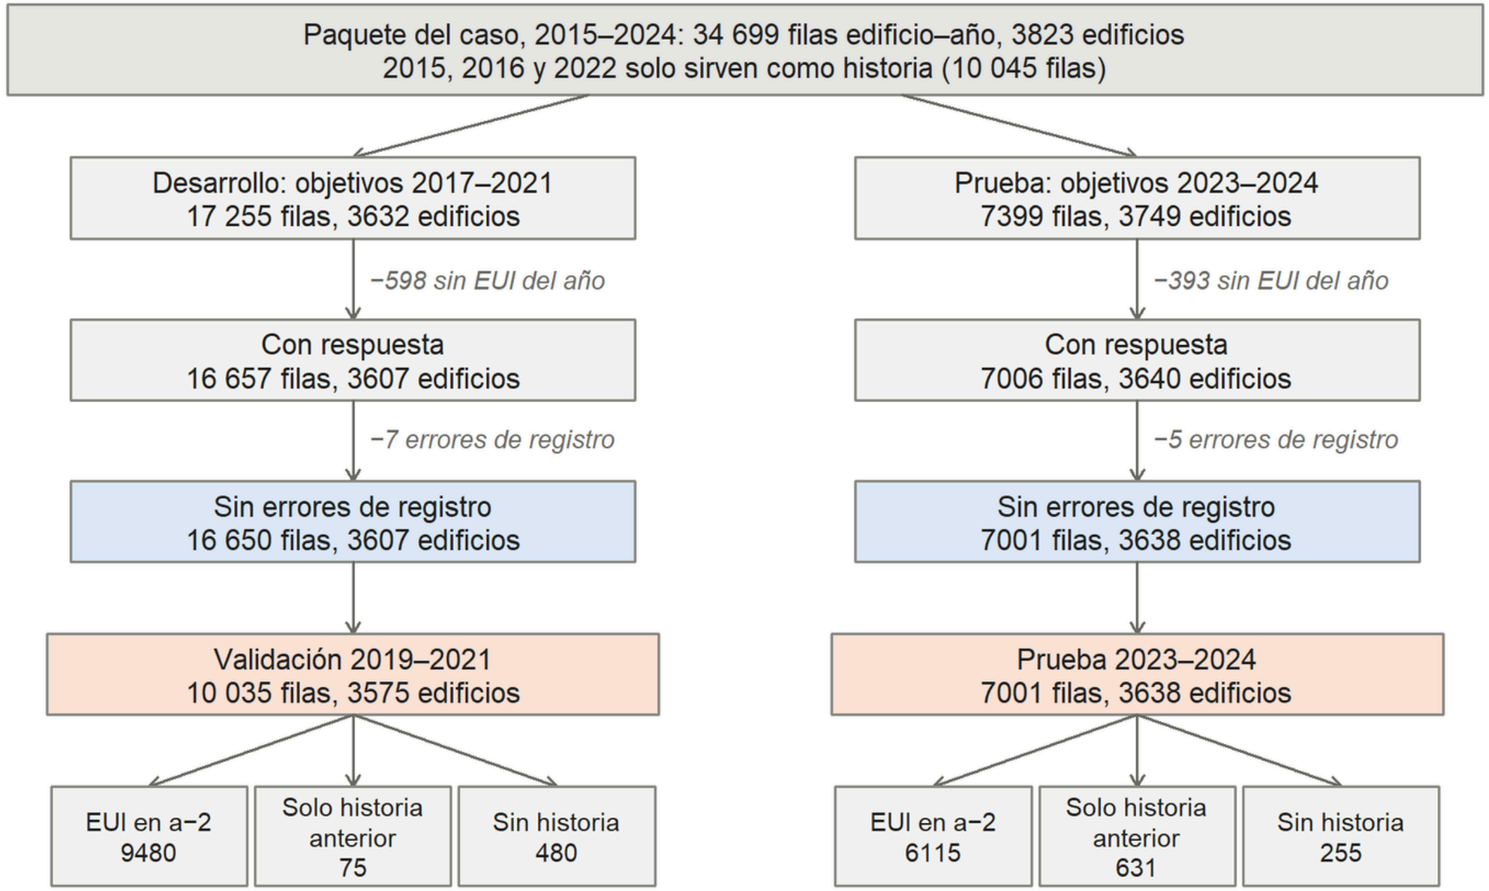
TRANSFORMACIÓN LOGARÍTMICA

Escala	Mín.	p1	p25	Mediana	p75	p99	Máx.	Media
EUI (kBtu/pie²)	0.10	5.80	27.60	37.20	57.60	283.46	1538.10	52.46
log(EUI)	−2.30	1.76	3.32	3.62	4.05	5.65	7.34	3.70

Anexo 1: Distribución de la respuesta en las 16 650 filas de desarrollo, sin errores de registro.

La asimetría es 7.3 en escala original y −0.1 en logaritmo. Las predicciones se devuelven a kBtu/pie² con la función exponencial.

CONSTRUCCIÓN DE LA MUESTRA



Anexo 2: Construcción detallada de la muestra.

Sin respuesta válida: se excluye la fila objetivo, no se imputa la EUI.

Unidad de análisis: edificio-año, con clave *osebuildingid* + *datayear*.

DETALLE DE LAS VARIABLES UTILIZADAS

Grupo	Columnas	Cómo entran o por qué se excluyen
Usadas: características del edificio	Barrio, tipo, año de construcción, pisos, edificios de la propiedad, superficie total y de estacionamiento	Valor actual. Entran como barrio, tipo, antigüedad, log de pisos, log de edificios, log de la superficie y fracción de estacionamiento.
Usadas: usos del edificio	Usos 1.° a 3.° y sus superficies	Último registro $\leq a-2$. Entran como uso principal, fracción de superficie de ese uso y número de usos.
Usadas: historia de la respuesta	EUI de los años $\leq a-2$	Log de la última EUI válida y de la EUI de $a-3$, con indicadoras.
Excluidas por fuga	13 medidas del año objetivo: consumo, emisiones y ENERGY STAR	Contienen la respuesta; sus valores pasados repetirían la historia de la EUI.
Excluidas por conocerse después	Distrito del concejo, cumplimiento del reporte y demolición	Usan límites de 2023, el cierre del reporte o el ciclo 2023.
Excluidas por identificar o repetir	Identificador y año (clave edificio–año), nombre, dirección, parcela y coordenadas; superficie de edificios y superficies autodeclaradas; tipo de propiedad EPA	Identifican al edificio (la ubicación entra como barrio) o repiten otra variable (sección 2.5).

Anexo 3: Variables utilizadas y excluidas.

CONFIGURACIÓN DE MODELOS

- **M1 Lasso**

Regresión penalizada sobre log(EUI).
λ elegido: 0.005332.
Conserva en promedio 23 de 49 coeficientes en desarrollo.

- **M2 GAM**

Agrega curvas suaves para historia, tamaño y antigüedad.
Configuración elegida: G1; curva para historia, indicadores de historia y tipo.

- **M3 Bosque aleatorio**

Capta interacciones sin especificarlas.
300 árboles; configuración elegida: mtry=5 y nodo mínimo=5.

Búsqueda de hiperparámetros

- Lasso: 20 valores de λ en escala logarítmica.
- GAM: 3 fórmulas de complejidad creciente (G1, G2 y G3).
- Bosque: 12 combinaciones de mtry $\in \{3, 5, 8, 12\}$ y nodo mínimo $\in \{5, 20, 50\}$.
- Total: 35 configuraciones evaluadas en las tres ventanas

COMPARACIÓN DESARROLLO Y PRUEBA

Procedimiento	MAE	RMSE	Dif. MAE
Referencia	10.44	24.0	—
Lasso	10.50	24.7	+0.06
GAM	10.52	24.5	+0.08
Bosque aleatorio	10.52	24.6	+0.08

Anexo 4: Resultados de desarrollo.

Las diferencias entre modelos son pequeñas dentro del desarrollo.

Procedimiento	MAE	RMSE
Referencia	10.69	28.2
Referencia alternativa	10.01	24.3
Lasso	9.86	26.3
GAM	9.84	23.9
Bosque aleatorio	9.50	22.7

Anexo 5: Resultados de prueba.

El bosque aleatorio minimiza el MAE de prueba, pero ya se había seleccionado el Lasso previamente.

MEJORA DEL LASSO

Historia disponible	n	Referencia ficha	Lasso	Dif. Lasso - ref.
EUI disponible en a-2	6115	9.20	9.08	-0.12
Solo historia anterior a a-2	631	22.77	15.16	-7.61
Sin historia	255	16.62	15.32	-1.30

Anexo 6: influencia de la historia disponible.

0.69 de los 0.84 kBtu/pie^2 de ventaja del modelo lasso proviene de las 631 filas sin EUI en a-2. La referencia alternativa también usa la última EUI válida y obtiene MAE de 15.13 en el grupo con historia antigua.

SENSIBILIDAD Y DIAGNÓSTICO

Sensibilidad	Resultado	Interpretación
S1: EUI en escala original	Lasso 11.23; GAM 11.42; RF 11.27	MAE aumenta con escala original
S2: edificios no vistos	721 edificios (20%) fuera de todo entrenamiento	MAE sube 0.14, 0.29 y 0.80
Sin regla de errores	Referencia 12.18; Lasso 10.74; GAM 11.74; RF 10.55	Registros erróneos afectan al MAE

Anexo 7: Análisis de sensibilidad.

REPRODUCIBILIDAD Y LÍMITES

- **Reproducibilidad**

Comando: Rscript --vanilla analisis.R
Repositorio: github.com/JuanPabloCuevas/Proyecto-EYP3407-Grupo-4
Commit: 14a84c6

- **Entorno**

R 4.5.3; Windows 11 x64.
Semilla 3407.
Paquetes: dplyr, glmnet, mgcv, ranger, rmarkdown y knitr.

- **Limitaciones**

Base descargada en 2026; atributos actuales copiados en años pasados; solo 2 años de prueba; población limitada a quienes reportan.